

## DEDICATÓRIA

**À amizade e a todo amor que ela pode trazer.**

## AGRADECIMENTOS

A Deus por todas as oportunidades e pessoas que colocou na minha vida.

Ao Instituto Federal de Educação, Ciência e Tecnológica do Ceará (IFCE) por ter oferecido um curso que me fez evoluir muito tanto profissionalmente como pessoalmente.

Aos professores e amigos do IFCE, em especial aos alunos da primeira turma de engenharia mecatrônica e aos bolsistas do Laboratório de Processamento de Energia (LPE), pelo companheirismo apoio e incentivo.

À Camilla Ramos e ao Atila Oliveira pela ajuda nos ensaios com o motor de indução.

Ao professor Dr. Cláudio Marques de Sá Medeiros por sua paciência e orientação para fazer com que eu tentasse sempre fazer o meu melhor.

À professora Renata pelo seu apoio, colaboração, presença e responsabilidade durante a composição do trabalho de conclusão de curso.

À Schneider Electric, pela oportunidade de estágio e primeiro emprego, e a todos com quem tive o prazer incomensurável de trabalhar.

Aos meus amigos do tempo de colégio, que ainda caminham ao meu lado e estão comigo para dividir memórias e alegrias.

Ao José Oniram Limaverde, pela ajuda na pesquisa de artigos científicos.

À Nice Aguiar, minha namorada, por toda paciência, carinho e atenção dispensados nesses anos de faculdade.

Aos meus pais Wiler e Irene, por sempre terem investido na minha educação e por serem literalmente tudo pra mim: exemplos de pessoas, pais, dedicação e amor.

Aos Meus irmãos Raquel e Wiler Junior, por serem exemplos nos quais eu sempre pude me espelhar e dos quais tenho bastante orgulho.

À minha família, por ter me apoiado mesmo eu não estando sempre presente.

“O sucesso nasce do querer, da determinação e persistência em se chegar a um objetivo. Mesmo não atingindo o alvo, quem busca e vence obstáculos, no mínimo fará coisas admiráveis.”

**José de Alencar**

## RESUMO

Este trabalho tem como objetivo a aplicação de um algoritmo computacional neural, não supervisionado, como forma de detectar e mapear falhas incipientes por curto-circuito entre espiras estatóricas de motores de indução trifásicos e a evolução destas falhas. Assim, é realizado um estudo de caso com um motor de 0,75 kW (1 CV) de fabricação WEG. Para extrair dados deste motor, uma bancada de testes e um sistema para emulação de curto-circuito entre espiras do estator são utilizados. A leitura das correntes do motor em questão é feita através de um sensor de efeito Hall. Os sinais de saída do sensor de efeito Hall são conectados a três entradas do sistema de aquisição de dados U2352 da Agilent. De posse dos dados, é utilizada a Transformada Rápida de Fourier (FFT) como recurso matemático para extração de características e, para a classificação dos dados entre motor com falhas ou com ausência destas, é utilizada a rede neural não supervisionada SOM 2-D (redes de Kohonen). Após treinamentos e testes, foi atingida uma taxa média de acerto na detecção de falhas da ordem de 88,32%, com desvio padrão de  $\pm 2,41\%$ .

Palavras-chave: Motores de Indução, Detecção de Falhas, Redes Neurais.

## ABSTRACT

This work aims at the application of an unsupervised artificial neural algorithm in order to detect and map three-phase squirrel-cage induction motor short circuit incipient faults and also the evolution of these failures. So, a case study is made with a 0.75 kW (1 CV) WEG's motor. To extract motor's data, a test mechanical structure and a short-circuit in stator windings emulation system are used. Readings of these currents are made by a Hall's effect sensor. The output signals of the Hall's Effect sensor are connected in three entries of Agilent's data acquisition system U2352. Having the data been already acquired, a Fast Fourier Transform (FFT) is made as a Mathematical resource for feature extraction, and, for the data classification between a motor with or without faults, the Self-Organizing Map (SOM) that is an unsupervised neural network is used. After trainings and tests, an 88.32% mean success rate with  $\pm 2.41\%$  normal deviation was achieved in fault detection.

Key-words: Induction Motors, Fault Detection, Neural Networks

## LISTA DE FIGURAS

Figura 1 - Tipos de Motores. Fonte: Franchi (2008) .....	7
Figura 2 - Componentes Típicos do motor de indução. Fonte: Bonnet (2010) ...	8
Figura 3 - Falhas em motores de indução na indústria química e de petróleo.	11
Figura 4 - Falha por curto-circuito. Fonte: Bonnet (2010).....	13
Figura 5 - Vizinhança Retangular .....	20
Figura 6 - Representação da rede SOM Matricial. Fonte: HAN (2006) .....	22
Figura 7 - Bobinamento de uma das fases do Motor de Indução Trifásico Fonte: Medeiros (2008) .....	26
Figura 8 - Passos e Etapas Preliminares. Fonte: Autor.....	28
Figura 9 - Estrutura Mecânica Inicial .....	30
Figura 10 - Estrutura mecânica final. Fonte: Autor. ....	30
Figura 11 - Circuito Amplificador de Instrumentação. Fonte: Fabbro (2002) ....	32
Figura 12 - Filtro Butterworth passa baixa, de ordem 2.....	33
Figura 13 - Esquemático final do circuito do Filtro. Fonte: Autor .....	34
Figura 14 - Resposta em frequência do filtro. Fonte: Autor .....	34
Figura 15 - Curva de Conjugado X Velocidade do Motor de Indução. Fonte: Fitzgerald (2006) .....	35
Figura 16 - Conexão do Sensor Hall ao Circuito Amplificador. Fonte: Autor. ...	38
Figura 17 - Motor Rebobinado com pontos disponíveis .....	39
Figura 18 - Esquema do aparato para emulação de falhas. Fonte: Autor. ....	40
Figura 19 - Erro x Épocas. Fonte: Autor.....	51
Figura 20 - Distribuição espacial dos neurônios. Fonte: Autor .....	52
Figura 21– Erro em função do número de épocas. Fonte: Autor.....	53
Figura 22 - Distribuição espacial dos neurônios.....	53
Figura 23 - Grade fixa de neurônios.....	54
Figura 24 - Espectro de Frequências do motor desacoplado e acoplado 1. Fonte: Autor.....	55
Figura 25 - Espectro de frequências do motor desacoplado e acoplado 2. Fonte: Autor.....	56
Figura 26 - Variância de cada frequência de saída da função FFT. Fonte: Autor .....	57
Figura 27 – Variância do espectro de frequências. Fonte: Autor.....	59
Figura 28 - Variância dos espectros de frequência utilizando apenas uma fase do motor. Fonte: Autor .....	60
Figura 29– Variância dos espectros de frequências com amostragem de 1 kHz, utilizando 3 fases do motor. Fonte: autor .....	61
Figura 30 - Sinal de corrente do estator sem a aplicação de carga .....	62
Figura 31 - Sinais de corrente do estator com aplicação de carga.....	63
Figura 32 - Motor em funcionamento normal ou com falha de alta impedância. ....	64

Figura 33– Motor em funcionamento normal ou com falha de baixa impedância.	
.....	64
Figura 34 - Erro durante o treinamento 1 da rede neural .....	68
Figura 35 - Grade bidimensional 1 de neurônios.....	69
Figura 36 - Curva de erro durante o treinamento .....	71
Figura 37 - Matriz de Neurônios .....	71
Figura 38 – Distribuição dos neurônios nos dados.....	74
Figura 39 - Erro durante treinamento 5 .....	75
Figura 40 - Gráfico bidimensional após treinamento 5 .....	76
Figura 41 - Grade de neurônios .....	76
Figura 42 - Erro durante o treinamento 6 .....	78
Figura 43 – Gráfico bidimensional após treinamento 6 .....	79
Figura 44 - Grade de neurônios .....	79
Figura 45 - Distribuição espacial dos neurônios.....	81
Figura 46 - Sequência lógica do algoritmo. ....	81

## LISTA DE TABELAS

Tabela 1 - Parâmetros para variação de velocidade de um motor de indução.	10
Tabela 2 - Porcentagem de falhas nos componentes dos motores de indução	12
Tabela 3 - Dados do sistema de Aquisição Agilent.....	23
Tabela 4 - Características dos Vetores.....	40
Tabela 5 - Resumo da Etapa A1.....	41
Tabela 6 - Resumo da Etapa A2.....	43
Tabela 7 - Resumo da Etapa A3.....	45
Tabela 8 - Definição da quantidade de neurônios utilizados.....	66



## LISTA DE SÍMBOLOS

$N$  - velocidade de rotação mecânica (em rpm)

$f_1$  – frequência fundamental da tensão de alimentação (em Hz)

$p$  – número de polos do motor

$s$  – escorregamento

$k$  – ordem das harmônicas temporais da fonte de alimentação

$n$  – ordem dos fluxos harmônicos espaciais

$x_n(t)$  – característica ou atributo do vetor de características

$X(t)$  – vetor de características

$w_i(t)$  – vetor de pesos do neurônio

$u_i(t)$  – produto interno entre vetor de características e neurônio

$w_i^*(t)$  – vetor de pesos do neurônio vencedor

$\eta$  – passo de aprendizagem

$\eta_0$  – passo de aprendizagem inicial

$t$  – iteração atual

$t_{max}$  – total de iterações

$h(i^*, i, t)$  – função de vizinhança

$V_0$  – tensão de saída

$x$  – atributo

$\mu$  – média

$\sigma$  – desvio padrão

$\alpha$  – definição de quanto os neurônios vizinhos terão seus pesos atualizados

# SUMÁRIO

<b>1</b>	<b>CAPÍTULO 1 - INTRODUÇÃO .....</b>	<b>1</b>
1.1	APRESENTAÇÃO DO TEMA E CONTEXTUALIZAÇÃO DO PROBLEMA DE PESQUISA .....	1
1.2	OBJETIVOS .....	1
1.2.1	Objetivo Geral .....	2
1.2.2	Objetivos Específicos .....	2
1.3	JUSTIFICATIVA .....	2
1.4	METODOLOGIA.....	3
1.5	ESCOPO .....	4
1.6	ESTRUTURA DO TRABALHO.....	4
<b>2</b>	<b>CAPÍTULO 2 – FUNDAMENTAÇÃO TEÓRICA .....</b>	<b>6</b>
2.1	MOTORES DE INDUÇÃO .....	6
2.2	FALHAS EM MOTORES DE INDUÇÃO TRIFÁSICOS .....	10
2.2.1	Falhas por excentricidade rotórica.....	12
2.2.2	Falhas devido à abertura de barras ou rachadura de anéis.....	12
2.2.3	Falhas por curto-circuito entre espiras estatóricas.....	13
2.3	DETECÇÃO DE FALHAS DE CURTO-CIRCUITO ENTRE ESPIRAS.....	15
2.4	REDES NEURAIS ARTIFICIAIS.....	15
2.4.1	Rede WTA.....	19
2.4.2	Rede SOM Linear .....	20
2.4.3	Rede SOM Matricial .....	21
<b>3</b>	<b>CAPÍTULO 3 – DESENVOLVIMENTO DA PESQUISA.....</b>	<b>23</b>
3.1	CONTEXTUALIZAÇÃO.....	23
3.2	EQUIPAMENTOS UTILIZADOS.....	23
3.2.1	Osciloscópio Tektronix TDS 210 .....	23
3.2.2	Fonte chaveada de tensão contínua – Minipa MPL-3305.....	24
3.2.3	Sistema de Aquisição de dados Agilent U2352 .....	24
3.2.4	Célula de Carga Aeph, Modelo TS - 20kg .....	25
3.2.5	Conversor de Frequência CFW-09 da WEG .....	25
3.2.6	Motor de Indução Trifásico Gaiola de Esquilo WEG (1CV).....	25
3.3	BASES PARA O DESENVOLVIMENTO DA PESQUISA.....	26
3.3.1	Estudos preliminares .....	26
3.3.2	Método para extração de características.....	27
3.4	PASSOS E ETAPAS PRELIMINARES .....	28

3.4.1	ETAPA P1 - Montagem da bancada para testes com motores de indução .....	29
3.4.1.1	Passo P1 – Base Mecânica .....	29
3.4.1.2	Passo P2 - Confeção das bobinas para o Freio de Foucault .....	31
3.4.1.3	Passo P3 - Sistema para medições indiretas de conjugado dos motores .....	31
3.4.1.4	Passo P4 - Ajuste e confecção do circuito impresso amplificador para o Sensor Hall	37
3.4.2	ETAPA P2 - Circuito para emular curto-circuito entre espiras do estator .....	38
3.4.3	ETAPA P3 - Aquisição de dados .....	40
3.5	PASSOS E ETAPAS DO DESENVOLVIMENTO DO ALGORÍTMO .....	41
3.5.1	Etapa A1 – Implementação do Algoritmo de treinamento e teste da rede Som Matricial	41
3.5.1.1	Aplicação e teste do conceito de competitividade .....	42
3.5.1.2	Aplicação e teste do conceito de vizinhança espacial .....	42
3.5.1.3	Implementação da Rede SOM Matricial .....	42
3.5.2	ETAPA A2 – Definições de Projeto e Análise dos Dados .....	42
3.5.2.1	Definição da referência de motor em funcionamento ideal .....	43
3.5.2.2	Definição da faixa do espectro de frequências .....	43
3.5.2.3	Definição das harmônicas utilizadas para a detecção de falhas .....	43
3.5.2.4	Definição da quantidade de fases necessárias para a detecção de falhas .....	44
3.5.2.5	Definição da frequência de amostragem .....	44
3.5.2.6	Análise das curvas de correntes no domínio do tempo .....	45
3.5.2.7	Análise dos dados no domínio da frequência e determinação da quantidade de neurônios utilizados na rede neural .....	45
3.5.3	ETAPA A3 – Treinamento, teste, ajustes e configuração final do algoritmo neural com dados de curto-circuito .....	45
3.5.3.1	Treinamento e teste 1 – Vizinhança variável desde o início do treinamento.	47
3.5.3.2	Treinamento e teste 2 – Vizinhança variável depois de determinadas iterações	48
3.5.3.3	Treinamento e teste 3 – Teste modificado: classificação apenas entre motores com ou sem falhas .....	48
3.5.3.4	Treinamento e teste 4 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de alta impedância ou com ausência de falhas. ....	48
3.5.3.5	Treinamento e teste 5 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de baixa impedância ou com ausência de falhas. ....	49
3.5.3.6	Ajuste e Configuração final do algoritmo para detecção de falhas .....	49

<b>4</b>	<b>CAPÍTULO 4 – RESULTADOS: APRESENTAÇÃO E ANÁLISE.....</b>	<b>50</b>
4.1	RESULTADOS DA ETAPA A1 – Implementação do algoritmo de treinamento e teste da rede SOM Matricial .....	50
4.1.1	Resultados da aplicação e teste do conceito de competitividade .....	50
4.1.2	Resultados da aplicação e teste do conceito de vizinhança espacial .....	52
4.1.3	Resultados da implementação da rede SOM matricial .....	54
4.2	RESULTADOS DA ETAPA A2 – Análise dos dados .....	55
4.2.1	Resultados da definição da referência de motor em funcionamento ideal.....	55
4.2.2	Resultados da definição da faixa do espectro de frequências .....	56
4.2.3	Resultados da definição das frequências harmônicas utilizadas para a detecção de falhas	57
4.2.4	Resultados da determinação do número de fases necessárias .....	59
4.2.5	Resultados da definição da frequência de amostragem .....	60
4.2.6	Resultados da análise das curvas de correntes no domínio do tempo.....	61
4.2.7	Resultado da análise dos dados no domínio da frequência e determinação da quantidade de neurônios utilizados na rede neural. ....	63
4.3	RESULTADOS DA ETAPA A3 - Treinamento, teste e ajuste do algoritmo neural com dados de curto-circuito. ....	66
4.3.1	Resultados do treinamento e teste 1 – Vizinhança variável desde o início do treinamento. ....	66
4.3.2	Resultados do treinamento e teste 2 – Vizinhança variável depois de determinadas iterações.....	69
4.3.3	Resultados do treinamento e teste 3 – Teste modificado: classificação apenas entre motores com ou sem falhas .....	72
4.3.4	Resultados do treinamento e teste 4 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de alta impedância ou com ausência de falhas.	74
4.3.5	Resultados do treinamento e teste 5 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de baixa impedância ou com ausência de falhas.	77
4.3.6	Resultados do Ajuste e Configuração final do algoritmo para detecção de falhas	80
<b>5</b>	<b>CAPÍTULO 5 – CONCLUSÃO .....</b>	<b>84</b>
5.1	Quanto ao tema .....	84
5.2	Quanto ao problema .....	84
5.3	Quanto aos objetivos .....	84
5.3.1	Específicos .....	84

5.3.2	Geral.....	85
5.4	Quanto à metodologia e procedimentos adotados .....	85
5.5	Quanto aos resultados obtidos .....	85
5.6	Limitações .....	85
5.7	Considerações gerais.....	86
5.8	Sugestões para trabalhos futuros .....	86

# **1 CAPÍTULO 1 - INTRODUÇÃO**

Este capítulo apresenta o tema da pesquisa, a definição do problema e sua justificativa, bem como a definição dos objetivos gerais e específicos e a limitação da pesquisa, além da estrutura da dissertação.

## **1.1 APRESENTAÇÃO DO TEMA E CONTEXTUALIZAÇÃO DO PROBLEMA DE PESQUISA**

Dentre os diversos tipos de motores (tais como mecânicos, elétricos, hidráulicos e pneumáticos) os elétricos são os mais utilizados atualmente nas indústrias (THANGARAJ, 2010). Isto acontece porque este tipo de máquina alia as vantagens da energia elétrica, como facilidade de transporte e simplicidade de comando, a uma construção simples, versatilidade e grandes rendimentos (MELLO JUNIOR; FAGÁ, 2005).

Porém, mesmo sendo muito robustos, estes motores são passíveis de falhas. Algumas das falhas que podem ser citadas são: a quebra de barras do rotor, curto-circuito entre espiras do estator, falhas de rolamento e falhas no eixo (BONNET, 2010). Dentre estas falhas, as falhas em rolamentos e nas bobinas do estator estão entre as de maior ocorrência (HAN *et al*, 2006).

A detecção prematura de falhas em motores pode se tornar um grande diferencial para uma determinada empresa, visto que o cenário industrial atual é extremamente competitivo e este tipo de detecção pode reduzir custos tanto de manutenção como de processo (HAN *et al*, 2006).

Assim, surge o problema a ser investigado neste trabalho: - Como se pode detectar prematuramente a ocorrência de falhas por curto-circuito entre espiras do estator de motores de indução trifásicos?

## **1.2 OBJETIVOS**

Neste trabalho, foram traçados os seguintes objetivos para solucionar o problema proposto:

### 1.2.1 Objetivo Geral

Aplicar um algoritmo computacional neural, não supervisionado (redes de Kohonen), como forma de detectar e mapear falhas incipientes por curto-circuito entre espiras estatóricas de motores de indução trifásicos e a evolução destas falhas.

### 1.2.2 Objetivos Específicos

Os objetivos específicos deste trabalho são:

- Estudar as possibilidades e métodos de detecção de falhas em motores de indução.
- Montar uma bancada de testes para extrair dados de correntes de motores de indução.
- Realizar ensaios representativos da operação da máquina em condições normais e sob níveis crescentes de falhas.
- Descrever as características especificações, requisitos para o desenvolvimento de uma rede neural não supervisionada.
- Projetar detector de falha baseado em rede neural não supervisionada do tipo mapas auto-organizáveis (*Self-organizing Maps* – SOM)
- Avaliar o desempenho do detector de falhas no tocante à capacidade de classificação e mapeamento

## 1.3 JUSTIFICATIVA

A escolha do tema deste trabalho foi baseada em alguns pontos. Primeiramente, este trabalho se justifica na grande importância que os motores de indução desempenham na indústria, por serem os mais utilizados atualmente. Também, as ferramentas computacionais estão cada vez mais presentes nas vidas das pessoas para a solução de problemas, pois os computadores estão cada vez com preços mais acessíveis e processadores mais rápidos.

Com essa capacidade de processamento cada vez maior, a aplicação das redes neurais em tempo real para detecção se torna possível, por isso vários estudos, como, por exemplo, em Yadav e Wadhwani (2011) e Weidong

*et al.* (2006), estão utilizando esses algoritmos para detecção e classificação de falhas.

Porém, na pesquisa realizada, não foi encontrado um banco de dados que fosse composto por dados reais de correntes do estator de um motor trifásico de indução nas condições normais de operação ou com falhas de alta ou baixa impedância. Assim, a ausência de um banco de dados que simulasse a evolução de um curto-circuito entre espiras do motor em estudo também justifica a realização deste trabalho.

Além disso, a detecção de falhas e o monitoramento periódico das condições de máquinas rotativas podem garantir eficiência, segurança e bom funcionamento destas máquinas, conduzindo, assim, a uma maior produtividade e redução na perda de capital nas indústrias (YADAV; WADHWANI, 2011). Futuramente, este estudo pode contribuir para a geração de um produto que otimize o tempo entre as manutenções de motores de indução trifásicos.

Com isso, este estudo pode vir a ser aplicado no meio industrial, pois existem inúmeros processos que utilizam motores de indução trifásicos.

## **1.4 METODOLOGIA**

Os conhecimentos gerados por esta pesquisa não são novos. Estes são voltados para solucionar o problema específico de detecção de falhas em motores. Assim, esta pesquisa é classificada como aplicada.

Além disso, as redes neurais são ferramentas matemáticas que lidam diretamente com números para classificar os problemas. No caso da rede neural utilizada nesta pesquisa, algumas das medidas estatísticas utilizadas são o erro quadrático médio, a média e o desvio padrão. Assim, esta pesquisa pode ser classificada como quantitativa.

Do ponto de vista dos objetivos, esta pesquisa pode ser caracterizada como exploratória, pois, através de referências que mostram que os sinais de corrente estatórica se modificam devido às falhas nos motores, foi elaborada a hipótese de que essas mudanças pudessem ser identificadas por redes neurais.



Por fim, do ponto de vista técnico, esta pesquisa é classificada como um estudo de caso, pois foram feitos inúmeros testes com o motor em questão para a implementação do algoritmo neural.

## 1.5 ESCOPO

Neste trabalho, todos os dados foram gerados a partir de um motor de indução trifásico gaiola de esquilo (1 CV de potência) da WEG. Este foi rebobinado para que também fossem simuladas condições de curto-circuito entre espiras.

Não é feita nem a simulação por *software* e nem o equacionamento dos harmônicos de um motor de indução. Isto ocorre porque este trabalho é a continuação de um projeto iniciado há dois anos, e o autor já estava de posse destes equacionamentos e simulações. Além disso, redes neurais artificiais não requerem um modelo matemático exato do motor.

O sensor utilizado para a extração de dados de corrente do motor é um sensor de efeito hall. Tentou-se utilizar uma célula de carga para extrair dados de conjugado do motor, porém surgiram algumas dificuldades na implementação, que são melhor detalhadas no Capítulo 3.

Não são extraídos dados de corrente durante o estado transitório do motor.

A detecção de falhas ocorre de modo *offline*, ou seja, o algoritmo não detecta a falha durante o funcionamento do motor.

Neste trabalho, são implementados alguns algoritmos neurais não supervisionados mais simples, até chegar à rede SOM Matricial.

Nos Capítulos 3 e 4, são mostradas as etapas de desenvolvimento da bancada de testes, aquisição dos dados, análise dos dados e teste da rede SOM matricial e seus resultados.

Por fim, no Capítulo 4, são mostrados os resultados obtidos da aplicação da rede neural proposta nos dados extraídos.

## 1.6 ESTRUTURA DO TRABALHO

O trabalho de pesquisa desenvolvido é estruturado da seguinte forma:

No Capítulo 2, é apresentada a fundamentação teórica sobre motores de indução trifásicos, falhas em motores, detecção destas, extração de características e redes neurais não-supervisionadas. No Capítulo 3 é apresentada a metodologia desenvolvida pelo autor, que inclui o desenvolvimento da bancada de testes, a aquisição dos dados e a implementação do algoritmo neural não supervisionado. No Capítulo 4, são mostrados e analisados de acordo com as bases teóricas, os resultados obtidos da aplicação deste algoritmo sobre o banco de dados extraídos do motor. Finalmente, no Capítulo 5, são mostradas as conclusões do projeto, as limitações deste e as sugestões para possíveis trabalhos futuros.

## **2 CAPÍTULO 2 – FUNDAMENTAÇÃO TEÓRICA**

Neste capítulo, são abordados os motores de indução trifásicos, os principais tipos de falhas que ocorrem nestas máquinas elétricas, bem como os métodos de extração de características e detecção destes tipos de falhas.

### **2.1 MOTORES DE INDUÇÃO**

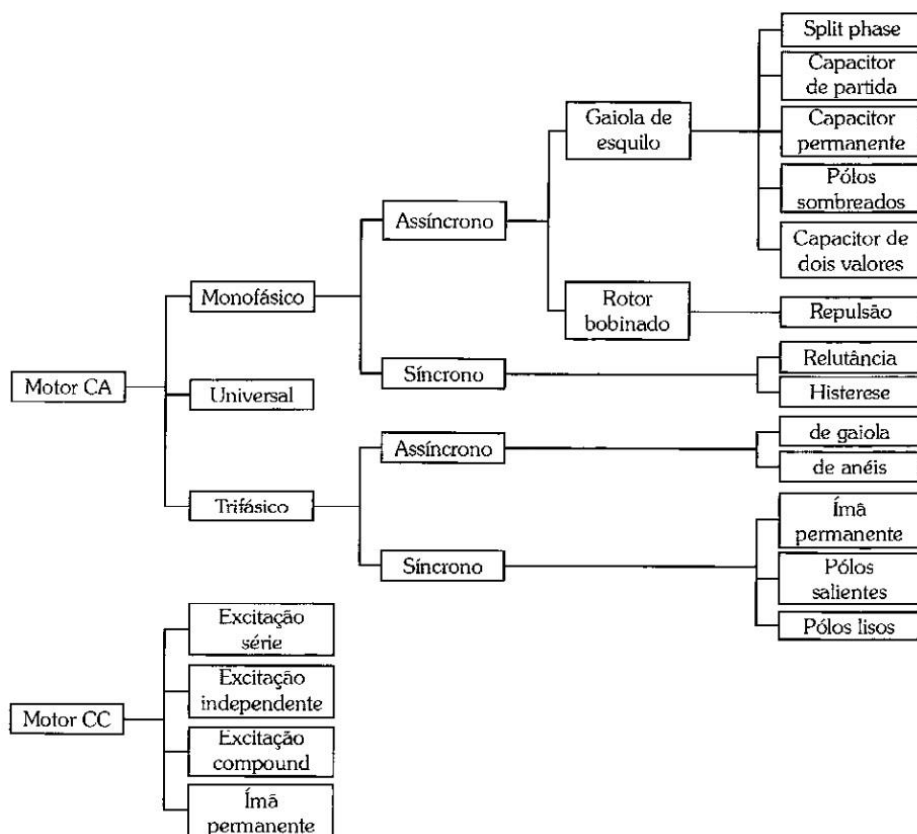
Além da ampla disponibilidade de energia elétrica nos pontos comerciais e industriais, a versatilidade e outras características dos motores elétricos, tais como instalação e construção, fazem com que esta máquina seja a mais utilizada mundialmente para a geração de força motriz em processos industriais, comerciais e agrícolas (MELLO JUNIOR; FAGÁ, 2005).

Compressores, ventiladores e centrífugas são algumas das máquinas que podem ser acionadas por este tipo de motor.

De acordo com sua fonte de alimentação, os motores elétricos podem ser classificados em dois grandes grupos: motores de corrente contínua (Motor CC) e de corrente alternada (Motor CA). Estes grupos são representados na Figura 1.

Os motores CC são conhecidos por apresentarem facilidade para o controle preciso de velocidade e ajuste fino, porém pelo seu alto custo em comparação com motores de indução, por não serem motores indicados para uso em ambientes adversos (SAWA; KUME, 2004) e por possuírem uma alta taxa de manutenção, estes não são amplamente utilizados industrialmente.

Assim, para a maioria das aplicações, a configuração mais econômica é conseguida através da utilização de um tipo específico de Motor CA: o motor de indução gaiola de esquilo. Por isso, “estima-se que 90% (em unidades) dos motores fabricados sejam desse tipo” (FRANCHI, 2008, p. 18).




**Figura 1 - Tipos de motores. Fonte: Franchi (2008).**

O princípio de funcionamento deste motor baseia-se nas leis fundamentais do eletromagnetismo tais como a Lei de indução de Faraday e a Lei de Lenz. Primeiramente é gerado um campo magnético girante, pela aplicação de corrente nos enrolamentos do estator. Este campo, ao atravessar o rotor, provoca uma variação de fluxo nos condutores deste. Como os condutores do rotor gaiola de esquilo estão em um circuito fechado, estes são percorridos por uma corrente induzida, que gera um campo magnético girante que gira no mesmo sentido do campo girante produzido pelo estator (FRANCISCO, 2006).

A interação entre estes dois campos produz um conjugado motor no mesmo sentido da velocidade do campo girante produzido pelo estator.

A estrutura do rotor gaiola de esquilo contribui para a simplicidade e robustez do motor em estudo, pois este tipo de rotor não exige o uso de escovas nem comutadores, evitando desgastes e manutenção. A estrutura básica do motor de indução pode ser visualizada na Figura 2.

## COMPONENTES TÍPICOS DO MOTOR



**Figura 2 - Componentes típicos do motor de indução. Fonte: Bonnet (2010).**

Além dessa característica, os motores de indução, em comparação com os Motores CC, têm como vantagens o rendimento elevado para médias e altas potências, um bom fator de potência e a simplicidade, que, juntamente com estudos para reduzir custos até no projeto (BRICKLEY, 1993), faz com que estes tenham baixo custo e máxima eficiência.

Todas essas vantagens fazem com que os motores de indução sejam os mais utilizados na indústria. Segundo Santos (2001), estudos recentes àquele ano mostravam que 50% de todas as cargas elétricas brasileiras já eram motores de indução. Segundo outro estudo Malijkovic *et al.* (apud THANGARAJ, 2010), 70% de todas as cargas industriais são representadas por motores de indução trifásicos.

Porém, este motor também possui algumas desvantagens, tais como uma alta corrente de partida e comportamento não linear (NIRALI; SHAH, 2011), o que torna seu controle complexo.

Por esse motivo, diversos estudos já foram feitos para o controle da sua velocidade e conjugado, envolvendo controle clássico e controle não-linear. Um

estudo recente utiliza três tipos de controladores (controle clássico, neural e Fuzzy) para controlar a velocidade de um motor de indução trifásico (NIRALI; SHAH, 2011).

Além disso, existem diversos tipos de conversores eletrônicos, tais como conversores de frequência escalares e conversores de frequência com controle vetorial, que tanto facilitam o controle de velocidade, quanto servem para economia de energia (SAWA; KUME, 2004).

A velocidade dos motores de indução é calculada por

$$N = \frac{120f_1}{2p} (1 - s) , \quad (1)$$

em que  $N$  é a velocidade de rotação mecânica (em RPM),  $f_1$  é a frequência fundamental da tensão de alimentação (em Hz),  $p$  é o número de pares de polos e  $s$  é o escorregamento do motor.

Na Tabela 1, podem ser observados os parâmetros através dos quais a velocidade destes motores pode ser variada. A partir dele, pode-se concluir que o parâmetro que possui as melhores características para variação de velocidade é a frequência da tensão estatórica, e os dispositivos eletrônicos utilizados para a variação deste parâmetro são os conversores de frequência (também chamados inversores de frequência).

Variação de Velocidade	
Parâmetro de variação de velocidade	Característica de aplicação
Número de Polos	Variação discreta Sobredimensionamento da carcaça
Escorregamento	Variação Contínua Perdas rotóricas Faixa de variação pequena
Frequência da tensão estatórica	Variação Contínua Uso de inversores de frequência

**Tabela 1 - Variação de velocidade de um motor de indução. Fonte: WEG (2009).**

Assim, neste trabalho, é utilizado o conversor de frequência CFW 09 de fabricação WEG para que seja realizada a simulação de falhas em várias velocidades de rotação do motor (WEG, 2011).

## **2.2 FALHAS EM MOTORES DE INDUÇÃO TRIFÁSICOS**

Mesmo com toda sua robustez, todas as vantagens e todos os estudos referentes ao motor de indução trifásico, este não é isento de falhas. Um estudo recente mostra que “a taxa de falhas em motores é conservadoramente estimada de 3 a 5% ao ano, mas, em algumas indústrias, como de cimento, mineração, celulose e papel, esta taxa chega a 12% ao ano” (VICO; HUNT, 2010, p. 1).


Com isso, pode-se concluir o quão importante é o monitoramento do motor de indução trifásico no meio industrial, pois diversas condições do ambiente podem levá-lo a falhar.

A maioria dessas falhas ocorre por uma combinação de vários estresses atuando nos enrolamentos do estator, no rotor, nos rolamentos e no eixo. Se qualquer uma das combinações de estresse exceder a capacidade de projeto do motor, falhas drásticas vão ocorrer e o tempo de vida do motor reduzirá bastante (BONNET, 2010).

Dentre tais estresses, podem ser citados a variação de tensão e a sobrecarga de tensão. Estes causam aquecimento no motor e, segundo Vico e Hunt (2010), a maioria dos contribuintes para a falha em motores está relacionada ao sobreaquecimento do motor.

As falhas mais comuns no motor de indução trifásico tipo gaiola de esquilo são falhas por excentricidade rotórica, falhas devido à abertura de barras ou rachaduras de anéis, falhas em rolamentos, e falhas no bobinamento estatórico.

Na Figura 3, por exemplo, pode-se observar a porcentagem destas falhas nas indústrias química e de petróleo. Nesta, pode-se observar que a maioria das falhas ocorre no rolamento (51%) e nos enrolamentos do estator (16%).



**Figura 3 - Falhas em motores de indução na indústria química e de petróleo. Fonte: Bonnet (2010).**

Em outro estudo, Singh e Kazzaz (apud HAN *et al.*, 2006) mostram algumas estatísticas gerais para falhas em motores retiradas de pesquisas feitas pelos institutos EPRI (*Electric Power Research Institute*) e IEEE (*Institute of Electrical and Electronics Engineers*). Estas pesquisas apontam uma grande ocorrência de falhas no estator do motor de indução trifásico. A quantificação do resultado desses estudos pode ser observada na Tabela 2. Nesta, também pode ser notada a grande ocorrência de falhas de rolamento e no estator.

	Falhas de Rolamento	Falhas de Estator	Falhas de Rotor	Outros
IEEE	42%	28%	8%	22%
EPRI	40%	38%	10%	12%

**Tabela 2 - porcentagem de falhas nos componentes dos motores de indução. Fonte: Han (2006).**



Assim, tanto a partir da Figura 3 quanto da Tabela 2, pode-se observar que as falhas mais recorrentes são as falhas de rolamento e as falhas no estator.

### **2.2.1 Falhas por excentricidade rotórica**

As falhas por excentricidade rotórica podem ser divididas em dois tipos: excentricidade estática ou dinâmica. A excentricidade estática ocorre quando a menor distância entre rotor e estator (entreferro) é fixa em determinado ponto do espaço, ou seja, a excentricidade permanece em um determinado ponto do espaço mesmo enquanto o motor está em funcionamento. Esta ocorre tanto pelo posicionamento incorreto do rotor ou estator durante a montagem do motor quanto pela ovalização do núcleo estatórico. Já na excentricidade dinâmica, a menor distância entre rotor e estator gira juntamente com o motor. Dentre os diversos motivos que originam esse tipo de falha podem ser citados o desalinhamento de rolamentos e o empenamento do eixo (MEDEIROS, 2008).

Dorrell *et al.* (1995) monitoraram falhas por excentricidade no motor de indução trifásico. Já Nandi *et al.* (2002) estudaram o motor de indução trifásico sob a influência de excentricidade mista.

### **2.2.2 Falhas devido à abertura de barras ou rachadura de anéis**

Quando ocorrem as falhas devido à abertura de barras, ocorre uma redução no desempenho mecânico e uma oscilação de conjugado, visto que, como não há mais corrente induzida nas barras “abertas”, estas passam a não mais produzir força magnetomotriz.

Barbour e Thomson (1997) fizeram uma investigação com o Método de Elementos Finitos, a qual revelou que o projeto das ranhuras rotóricas possui considerável efeito sobre a magnitude das componentes de corrente, especialmente quando uma excentricidade estática está presente.

Segundo Nandi *et al.* (2002), de 5% a 10% das falhas em motores de indução, são devidas à abertura de barras ou rachaduras de anéis.

### 2.2.3 Falhas por curto-circuito entre espiras estatóricas

Segundo Nandi *et al.* (2005), em torno de 30% a 40% de todas as falhas no motor de indução ocorrem em consequência de falhas por curto-circuito

Esse tipo de falha se dá principalmente por alta temperatura do bobinamento ou núcleo estatóricos; folga na laminação do núcleo magnético estatórico, perda da proteção das conexões de bobinas; contaminação provocada por óleo, umidade ou sujeira; descargas elétricas; e vazamentos no sistema de arrefecimento (NANDI *et al.*, 2005).

Devido ao *stress*, o processo de falha inicia-se primeiramente com uma falha de alta impedância entre espiras da mesma fase, entre fases ou para o terra (NATARANJAN, 1989).

Depois desse *stress* inicial, a corrente de falta pode causar aquecimento localizado, provocando um rápido alastramento da falha de bobinamento (TALLAM *et al.* 2003).

Na Figura 4, pode-se observar um curto-circuito entre espiras da mesma fase de um estator. Esta ocorreu pela perda de isolamento causada por temperatura excessiva dos enrolamentos.




Figura 4 - Falha por curto-circuito. Fonte: Bonnet (2010).

Segundo Thomson (2001), se esse tipo de falha for detectado no primeiro estágio de desenvolvimento, a máquina pode ser reutilizada após o rebobinamento do estator.

Assim pode-se concluir que a implementação de um detector de falhas na fase inicial de um curto-circuito faria com que as máquinas pudessem ser utilizadas por mais tempo, sem que fosse necessário trocá-las.

Penman *et al.* (1994) propôs um método para detectar falhas de bobinamento estatórico baseado na determinação de harmônicas específicas de tensão induzidas num bobinamento instalado concentricamente ao eixo do motor.

A expressão generalista das componentes harmônicas devido à falha de bobinamento estatórica foi derivada como

$$f_h = \left[ \frac{k \pm n(1-s)}{p} \right] f_1, \quad (2)$$

onde  $p$  é o número de pares de polos,  $s$  é o escorregamento,  $n$  é a ordem dos fluxos harmônicos espaciais,  $k$  é a ordem das harmônicas temporais da fonte de alimentação e  $f_1$  é a frequência fundamental da fonte de tensão. Apenas as harmônicas de baixa ordem são significantes. Os elementos chave para esta expressão ocorrem para  $k = 1, 3$  e  $n = 1, 2, 3, \dots, (2p - 1)$ .

Mesmo a Equação 2 sendo desenvolvida para o bobinamento instalado concentricamente ao eixo, esta pode ser usada também para detectar falhas no bobinamento do motor pela observação do espectro de frequência da corrente estatórica, pois esse fluxo também atinge as bobinas do estator.

Já em Joksimovic e Penman (2000), é mostrado que nenhuma componente de frequência nova aparece no espectro de frequências como consequência de falha no bobinamento estatórico, ou seja, apenas há a variação da amplitude de componentes de frequências já existentes. Além disso, estas frequências também variam em decorrência de outras falhas.

Assim, como esse tipo de falha tem grande relevância, e como se torna difícil detectar prematuramente o curto-circuito entre espiras, pois este se alastra muito rápido e começa inicialmente por uma falha de alta impedância, este tipo de falha foi escolhido para ser estudado neste trabalho.

## 2.3 DETECÇÃO DE FALHAS DE CURTO-CIRCUITO ENTRE ESPIRAS

Diante de todas as falhas existentes, diversos estudos e técnicas foram desenvolvidos para a detecção das falhas em motores de indução trifásicos.

Killman (1999) fez um estudo sobre a relação entre a assinatura de frequência nas correntes do estator decorridos de vibrações mecânicas. Já Bellini (1999) estudou o impacto do controle em malha fechada no diagnóstico de falhas em motores de indução. Cardoso (1993) utilizou leitura de correntes do estator com aproximação por vetor de Park para detectar excentricidade em motores de indução trifásicos. Benbouzid (1999) fez uma revisão bibliográfica sobre detecção e diagnóstico de falhas em motores de indução.

Dentre as técnicas de detecção de falhas, além de ferramentas matemáticas, os algoritmos computacionais em geral são muito utilizados devido ao contínuo avanço e a facilidade trazida pelos computadores.

Como exemplos de algoritmos computacionais podem ser citados: Lógica Fuzzy (SHAH; SALIM, 2006), Análise de Componentes Independentes (WEIDONG *et al.*, 2006), Algoritmos Genéricos (INDIRA; RAMESH, 2011) e Redes Neurais Artificiais (GHATE; DUDUL, 2010).

Hush *et al.* (1997) fizeram um estudo de caso da aplicação de redes neurais em detecção de falhas. Segundo estes, uma rede neural pode ser utilizada como aparelho de monitoramento, para detectar a maioria das mudanças na operação de um sistema.

Além disso, muitos problemas de detecção de falhas podem ser considerados como um problema de classificação. Segundo Zang (2000, p. 451), “As vastas atividades de investigação sobre classificação neural estabeleceram que as redes neurais são uma alternativa promissora a vários métodos de classificação convencionais”.

Por isso, o algoritmo implementado neste projeto se baseou em uma rede neural.

## 2.4 REDES NEURAIS ARTIFICIAIS

As redes neurais artificiais são sistemas que têm como elemento básico o neurônio artificial. Estes simulam a capacidade do cérebro humano de processar informações complexas de forma não linear e paralela.

Segundo Haykin (2001, p. 28), “uma rede neural é um processador maciçamente paralelamente distribuído constituído de unidades de processamento simples, que têm a propensão natural para armazenar conhecimento experimental e torná-lo disponível para uso”.

Existem características destas redes que as tornam atrativas na solução de problemas. Segundo Zang (2000), primeiramente, redes neurais podem se adaptar aos dados sem que haja uma especificação explícita para o modelo em estudo. Além disso, estas podem aproximar qualquer função com uma precisão arbitrária. Também, estas são modelos não lineares, o que faz com que estas possam modelar as complexas relações do mundo real.

O algoritmo das redes neurais se baseia em dois princípios: treinamento e generalização. “Treinamento é a habilidade de aproximar o comportamento subjacente, adaptando-se a partir dos dados de formação enquanto generalização é a capacidade de prever além dos dados de treinamento” (ZANG, 2000, p. 454).

Diversos estudos e aplicações já foram feitos por causa das vantagens das redes neurais artificiais. Dentre eles podem ser citados a detecção de falhas em conversores de frequência em sistemas de energia eólica (YOU; ZHANG, 2012), controle sem sensoramento de velocidade de um motor de indução (RONGFENG et al. 2010) e o diagnóstico de problemas em plantas industriais com descrição desconhecida (TZAFESTAS, 2002).

As redes neurais podem ser divididas em três tipos principais: Redes alimentadas adiante com camada única, redes alimentadas diretamente com múltiplas camadas e redes recorrentes (HAYKIN, 2001).

Dentre estas, a rede neural MLP (*multi-layer perceptron*), que é um tipo de rede alimentada diretamente com múltiplas camadas, é muito estudada e utilizada como classificador neural (ZANG, 2000). Isto acontece pelo fato de que esta “tem se mostrado uma ferramenta poderosa na modelagem de mapeamentos entrada-saída tipicamente encontrados em problemas de aproximação de funções (regressão) e classificação de padrões” (MEDEIROS, 2008, p. 7).

Porém, este trabalho não visa apenas à aplicação de uma rede neural que seja capaz de classificar um motor em funcionamento com ou sem falhas.

Um dos objetivos deste é montar um mapa bidimensional de neurônios, onde cada região deste mapa seja representativa de um modo de funcionamento do motor.

Com isso, este mapa pode servir de base para um futuro sistema supervisorio de motores, visto que, apenas observando qual região do mapa representa o dado de entrada atual do motor, poderá ser constatado o estado atual do motor.

Assim, a rede neural MLP não seria a mais indicada para esta aplicação, mas sim a rede SOM (*Self-Organizing Map* ou mapa auto-organizável), também conhecida por redes de Kohonen (KOHONEN, 1990), pois esta pode representar uni ou bidimensionalmente um problema multivariáveis.

Segundo Haykin (2001, p. 483), “um mapa auto-organizável é caracterizado pela formação de um mapa topográfico dos padrões de entrada, no qual as localizações espaciais dos neurônios na grade são indicativas das características estatísticas intrínsecas contidas nos padrões de entrada”.

Esta característica é importante para um futuro sistema de supervisão, visto que esta rede neural pode permitir o mapeamento das falhas no plano bidimensional.

Isto ocorre porque a rede SOM é um algoritmo do tipo não supervisionado. Neste algoritmo, os neurônios competem entre si e podem ser organizados em grupos (KOHONEN, 1990). A estes grupos podem ser atribuídos rótulos que caracterizam as similaridades contidas no conjunto de entrada.

Para utilizar uma rede neural não supervisionada, é necessário possuir um número finito de  $N$  exemplos de treinamento, onde cada um representa um “vetor de características”. Este vetor pode ser representado por

$$X(t) = (x_1(t) \dots x_n(t))^T, \quad (3)$$

no qual cada elemento  $x_j(t)$ ,  $j = 1, \dots, n$  é chamado de característica ou atributo, e representa uma informação relevante para análise do problema a ser solucionado. O conjunto destes vetores constitui um banco de dados.

Além disso, redes neurais competitivas constituem uma das principais classes de redes neurais, nas quais um ou um grupo de neurônios são modificados de acordo com a proximidade em relação ao vetor de entrada atual. As redes neurais utilizadas neste trabalho se baseiam na determinação do neurônio cujo vetor de pesos está mais próximo do vetor de entrada atual (chamado de neurônio vencedor). Os vetores de pesos tem a mesma “dimensão” dos vetores de entrada e podem ser representados por

$$w_j = (w_{j1}, w_{j2}, \dots, w_{jn}), \quad j = 1, 2, \dots, l, \quad (4)$$

onde  $l$  é o número total de neurônios e  $w_j$  é o vetor de pesos do neurônio (HAYKIN, 2001).

Existem diversas maneiras de medir a “proximidade” entre o vetor de entradas atual e um neurônio e, neste caso, como a distância euclidiana é frequentemente utilizada (MONTEIRO, 2009), esta foi usada neste trabalho e é representada por

$$\|x(t) - w_i(t)\| = \sqrt{[x(t) - w_i(t)]^T [x(t) - w_i(t)]} = \sqrt{\sum_{j=1}^n [x_j(t) - w_{ij}(t)]^2}. \quad (5)$$

O neurônio dito vencedor ( $w_i^*$ ), é aquele cujo vetor de pesos possui a menor distância euclidiana do vetor de entrada atual.

Zahng *et al.* (2008) utilizou uma rede SOM para a identificação de espécies de plantas, já Ji-Hong *et al.* (2011) utilizaram análise visual da distribuição espacial dos neurônios da rede SOM para diagnóstico de falhas em motores de indução. Também, Xu *et al.* (2008) utilizaram rede SOM para reconhecimento de modulação digital em sinais de comunicação.

Dentre as redes neurais não supervisionadas, foram implementadas para testes, neste trabalho, as redes com os seguintes algoritmos de treinamento: WTA, SOM Unidimensional (1-D) e SOM Bidimensional (2-D).

No caso deste trabalho, a implementação do algoritmo de treinamento da rede SOM ocorreu antes da aquisição dos dados de corrente do motor. Para verificar a robustez do algoritmo, foram utilizados três bancos de dados

conhecidos pela comunidade científica: Íris, Dermatologia e Vinho (FRANK; ASUNCION, 2010). Todos estes estão descritos no Apêndice A.

#### 2.4.1 Rede não supervisionada com algoritmo de treinamento WTA

A rede WTA (*Winner-take-all*) é o algoritmo onde apenas um neurônio de saída está ativo em dado instante de tempo (HAYKIN, 2001), ou seja, apenas o neurônio vencedor tem seu vetor de pesos modificado em relação ao vetor de entradas atual. Assim, este algoritmo foi considerado mais simples e foi o primeiro a ser testado. Seu algoritmo de treinamento consiste de três passos que se repetem durante  $N$  ciclos (onde  $N$  é o número de vetores de características destinados ao treinamento):

- 1º: Seleção aleatória de um vetor de características como vetor de entrada atual.
- 2º: Busca pelo neurônio vencedor em relação ao vetor de entrada atual.
- 3º: Atualização do vetor de pesos do neurônio vencedor. Esta atualização é definida por (HAYKIN, 2001)

$$w_i(t + 1) = w_i(t) + \eta[x(t) - w_i(t)], \quad (6)$$

onde  $0 < \eta < 1$  é o passo de aprendizagem. Para que haja maior probabilidade da convergência, é comum fazer com que o passo de aprendizagem decresça com o tempo (época de treinamento). Algumas das funções utilizadas nos testes são

$$\eta(t) = \frac{\eta_0}{1+t} t_{max} \quad e \quad (7)$$

$$\eta(t) = \eta_0 \left(1 - \frac{t}{t_{max}}\right), \quad (8)$$

onde  $t$  é a iteração atual,  $\eta(t)$  é a taxa de aprendizagem atual,  $\eta_0$  é a taxa de aprendizagem inicial e  $t_{max}$  é o número total de iterações.

Estas funções ajudam na convergência do erro durante o treinamento, porém estas têm como característica a atribuição de uma importância maior aos vetores de características apresentados inicialmente aos neurônios, e isto pode gerar erros na generalização do problema.



### 2.4.2 Rede não supervisionada com algoritmo de treinamento SOM unidimensional

Tanto esta rede quanto a rede SOM 2-D diferem da WTA por estarem em uma “grade fixa”. Assim, pode-se definir uma relação de vizinhança espacial entre os neurônios. Seu algoritmo é bem parecido com o da rede WTA, porém a diferença entre eles está no fato de que não só o vetor de pesos de um neurônio vencedor é atualizado a cada vetor de entrada apresentado, mas também o vetor de pesos dos vizinhos a este neurônio. A forma de atualização dos pesos é dada por (HAYKIN, 2001)

$$w_i(t+1) = w_i(t) + \eta(t)h(i^*, i, t)[x(t) - w_i(t)], \quad (9)$$

onde  $h(i^*, i, t)$  é a função de vizinhança, e seu valor pode ser definido por: “1” se o neurônio faz parte da vizinhança do neurônio vencedor, e “0” se o neurônio não fizer parte da vizinhança do neurônio vencedor. Esta é a vizinhança retangular proposta por Kohonen. Na Figura 5, está representado este tipo de vizinhança em uma rede neural bidimensional.




Figura 5 - Vizinhança Retangular. Fonte: Autor.

Porém, uma função de vizinhança comumente utilizada é função gaussiana (MONTEIRO, 2009), visto que esta é mais biologicamente apropriada que uma função retangular, faz com que o algoritmo convirja mais rapidamente e tem as seguintes características (HAYKIN, 2001):

- A vizinhança topológica decresce com o aumento da distância lateral entre os neurônios (condição necessária para a convergência).
- A vizinhança topológica é simétrica em relação ao ponto máximo (valor unitário), e este ponto se dá no neurônio vencedor.

A função gaussiana pode ser definida por

$$h(i^*, i, t) = \exp\left(-\frac{\|r_i(t) - r_{i^*}(t)\|^2}{2\alpha^2(t)}\right), \quad (10)$$

onde  $r_i(t)$  e  $r_{i^*}(t)$  são as posições geométricas do neurônio a ser atualizado e do neurônio vencedor, respectivamente, e  $\alpha(t)$  é o raio de influência da função de vizinhança, ou seja,  $\alpha$  é o parâmetro que define a quantidade de neurônios vizinhos que tem seus pesos atualizados (MONTEIRO, 2009).

Uma escolha popular para a dependência de  $\alpha$  com o tempo discreto  $t$  é o decaimento exponencial (HAYKIN, 2001). Este pode ser calculado por

$$\alpha(t) = \alpha_0 \exp(-t/\tau_1), \quad (11)$$

em que  $\alpha_0$  é o valor inicial de  $\alpha$  e  $\tau_1$  é uma constante de tempo.


No caso da rede SOM 1-D, os vizinhos estão dispostos “em linha”, ou seja, apenas existem vizinhos à esquerda ou à direita.

#### **2.4.3 Rede não supervisionada com algoritmo de treinamento SOM Bidimensional**

Esta rede difere da rede SOM 1-D por possuir uma “grade fixa” de duas dimensões, ou seja, os neurônios estão dispostos em linhas e colunas, podendo haver vizinhos à esquerda, à direita, acima, abaixo e diagonalmente. Assim, o algoritmo desta é semelhante ao da rede SOM1-D.

A Figura 6 representa a topologia da rede SOM 2-D. Nesta rede neural, a camada de entrada é composta pelos vetores de características, e a camada de saída são os neurônios distribuídos espacialmente.

A partir da fundamentação teórica desenvolvida neste capítulo, são mostrados, no Capítulo 3, as ferramentas e o passo-a-passo necessários para atingir os objetivos propostos por esse trabalho.



**Figura 6 - Representação da rede SOM 2-D. Fonte: Han (2006).**

### **3 CAPÍTULO 3 – DESENVOLVIMENTO DA PESQUISA**

#### **3.1 CONTEXTUALIZAÇÃO**

Como este trabalho não se resume somente à implementação de uma rede neural ou a aplicação desta em dados simulados, foi necessária a construção de uma bancada de testes e a utilização de alguns equipamentos para coletar dados do motor de indução trifásico gaiola de esquilo.

Com isso, o trabalho aqui descrito foi desenvolvido no Laboratório de Processamento de Energia (LPE) e no Laboratório de Máquinas Elétricas (LME), ambos do Instituto Federal de Ciência, Educação e Tecnologia do Ceará (IFCE). Estes forneceram tanto um ambiente propício para os testes como uma boa quantidade de ferramentas que facilitaram o desenvolvimento deste trabalho.

A seguir são mostrados os equipamentos utilizados, as bases para o desenvolvimento da pesquisa, e os passos tanto da construção da bancada de testes como da implementação do algoritmo.

#### **3.2 EQUIPAMENTOS UTILIZADOS**

Nesta seção, os equipamentos utilizados para aquisição de dados, testes e desenvolvimento do trabalho são descritos. A imagem de alguns desses equipamentos estão disponibilizadas no Apêndice C.

##### **3.2.1 Osciloscópio Tektronix TDS 210**

Este equipamento serviu para a verificação visual dos sinais de corrente do motor de indução trifásico antes da aquisição destes.

As características deste osciloscópio são (TEKTRONIX, 2012):

- Osciloscópio com dois canais de tempo real – 60 MHz – 1 GS/s,
- 60 MHz ou 100 MHz com uma taxa de aquisição de 1 GS/s em todos os canais,
- 2 e 4 padrões de canais,
- Base de tempo dual,
- medições automáticas,

- Interface com o usuário através de várias línguas,
- Auto ajuste,
- Memórias de *setup* e formas de onda,
- Capacidade estendida disponível através de módulos opcionais, software e pontas de prova.

Este instrumento é utilizado para a leitura dos sinais de saída dos sensores utilizados neste projeto. Como foi utilizado um sistema de aquisição de dados, foi necessário visualizar estes sinais antes de se conectar os sensores ao sistema.

### 3.2.2 Fonte chaveada de tensão contínua – Minipa MPL-3305

Esta fonte foi utilizada inicialmente para a alimentação do circuito amplificador do sensor Hall. Porém, como apareceram diversos ruídos vindos da rede de alimentação, utilizou-se duas baterias de 9 V para isolar o circuito amplificador da rede de alimentação.

### 3.2.3 Sistema de Aquisição de dados Agilent U2352

Este instrumento é utilizado para aquisição dos dados de corrente obtidos. Na tabela 3 podem ser vistas algumas especificações fornecidas pelo fabricante.

Número do modelo	U2352A
Entrada analógica	
Resolução	16 bits
Número de Canais	24 canais
Máxima taxa de amostragem	250 Ka/s
Faixa de entrada bipolar programável	+10 V +5 V, +2,5 V +1,25 V
Faixa de entrada unipolar programável	0 a 10 V, 0 a 5 V, 0 a 2,5V, 0 a 1,25 V
Acoplamento de entrada	DC
Impedância de entrada	1 G $\Omega$ / 100 pF
Faixa de tensão do modo comum de operação	Máximo +-7,5 V
Proteção contra sobretensão	Ligado: +-30 V, Desligado: +-15 V

**Tabela 3 - Dados do sistema de Aquisição Agilent. Fonte: Agilent Technologies (2012)**

### 3.2.4 Célula de Carga Aeph, Modelo TS – 20 kg

Este transdutor foi utilizado para medição indireta de conjugado do motor. A seguir são descritas algumas características deste:

- Material: Alumínio anodizado,
- Sensibilidade: 2 mV/V +/- 10%,
- Faixa de temperatura Nominal: - 10°C a + 40°C,
- Não linearidade: < 0,03% FSO,
- Sobrecarga segura (sem ruptura): 150%,
- Tensão Recomendada: 10 V,
- Máxima tensão (VDC ou VCA): 15 V,
- Resistência Elétrica de entrada:  $410 \Omega \pm 30 \Omega$ ,
- Resistência Elétrica de saída:  $350 \Omega \pm 3 \Omega$ ,
- Resistência de isolamento:  $> 2 G\Omega$ ,
- Grau de Proteção: IP-67,

### 3.2.5 Conversor de Frequência CFW-09 da WEG.

Este conversor é utilizado para atribuir diferentes velocidades ao motor de indução e por apresentar as especificações necessárias para alimentar esta máquina elétrica.

As velocidades utilizadas para alimentação do motor foram de 30, 35, 40, 45, 50, 55 e 60 Hz.

- Frequência de Chaveamento do conversor: 10 kHz

### 3.2.6 Motor de Indução Trifásico Gaiola de Esquilo WEG (1 CV)


O motor utilizado neste trabalho possui as seguintes características:

- Código da Placa: Motor WEG 03OUT05 GX59201,
- Potência: 0,75 kW (1CV),
- Velocidade nominal:  $n = 1720$  rpm,
- Fator de Serviço: FS = 1,15,
- Corrente de pico/Corrente nominal:  $I_p/I_n = 7,2$ ,
- Tensão: U = 220/380 V,
- Corrente Nominal: I = 3,02/1,75 A,

- Rendimento:  $\eta = 79,5\%$ ,
- Fator de Potência:  $\cos(\varphi) = 0,82$ .

O motor utilizado neste trabalho foi previamente rebobinado para que simulações de curto-circuito entre espiras do estator fossem feitas.

“Originalmente cada fase do motor é composta por 2 grupos de 3 bobinas com 58 espiras, perfazendo um total de 348 espiras” (MEDEIROS, 2008). Porém, apenas 2 terminais por fase são disponibilizados para a ligação do motor. Uma fase deste motor é representada na Figura 7.



**Figura 7 - Bobinamento de uma das fases do Motor de Indução Trifásico Fonte: Medeiros (2008)**

Após o rebobinamento (feito por uma empresa especializada), algumas derivações da bobina “B1” de cada fase do motor ficaram disponíveis para as simulações de curto-circuito.

### 3.3 BASES PARA O DESENVOLVIMENTO DA PESQUISA

#### 3.3.1 Estudos preliminares

Os estudos preliminares sobre motores de indução trifásicos foram feitos através dos trabalhos de Franchi (2006) e Fitzgerald *et al.* (2008).

Além disso, neste trabalho, o algoritmo de redes neurais proposto para a detecção de falhas por curto-circuito entre espiras do motor são as “Redes de Kohonen” (especificamente a rede SOM 2-D). Assim, para programá-lo, foram

necessários estudos preliminares. Estes estudos foram realizados através dos trabalhos de Haykin (2001) e Kohonen (1990).

Por fim, a aquisição dos dados reais utilizados neste projeto foi feita por um dos “dispositivos de aquisição de dados multifuncionais USB Agilent série U2300A”. Neste trabalho, o dispositivo utilizado foi o U2352A.

Assim, também foi necessário um estudo preliminar para que as aquisições fossem feitas com o menor número de erros e para que fosse utilizada a maior quantidade de recursos possíveis que esse dispositivo pudesse fornecer.

### **3.3.2 Método para extração de características**

Os dados utilizados, neste trabalho, para a detecção de falhas, foram obtidos pela leitura das correntes do estator do motor de indução trifásico através de um sensor de efeito Hall.

Este é um transdutor que varia sua tensão de saída em função de uma variação de campo magnético. A escolha deste, no presente trabalho, se deve principalmente ao fato de que este sensor é não invasivo, ou seja, não é necessário desviar parte da corrente que passa por um condutor para que seja feita a medição da corrente.

Isto ocorre porque um condutor percorrido por uma corrente elétrica gera um campo magnético proporcional a esta, tornando simples a leitura de corrente por parte do sensor de efeito Hall.

O método para aquisição de dados está descrito na Seção 3.4 (etapas preliminares).

Depois da aquisição de dados, o método utilizado para extrair características destes dados, pelo qual a rede neural pudesse detectar as diferenças entre os motores com falha e com funcionamento normal, foi a transformada rápida de Fourier (FFT). Esta foi aplicada no sinal obtido pelo sistema de aquisição. Posteriormente foram analisados os espectros de frequência gerados.

A Transformada de Fourier, em termos de esforço computacional é complexa e caracterizada como lenta e ineficaz para aplicações de alto desempenho (REIS, 2008), por isso a FFT foi aplicada para que o esforço computacional fosse reduzido.



### 3.4 PASSOS E ETAPAS PRELIMINARES

Estes passos e etapas não fazem parte da construção do algoritmo, porém estes foram de extrema importância para a formação do banco de dados utilizado para a detecção de falhas. Os passos e etapas preliminares são mostrados na Figura 8.

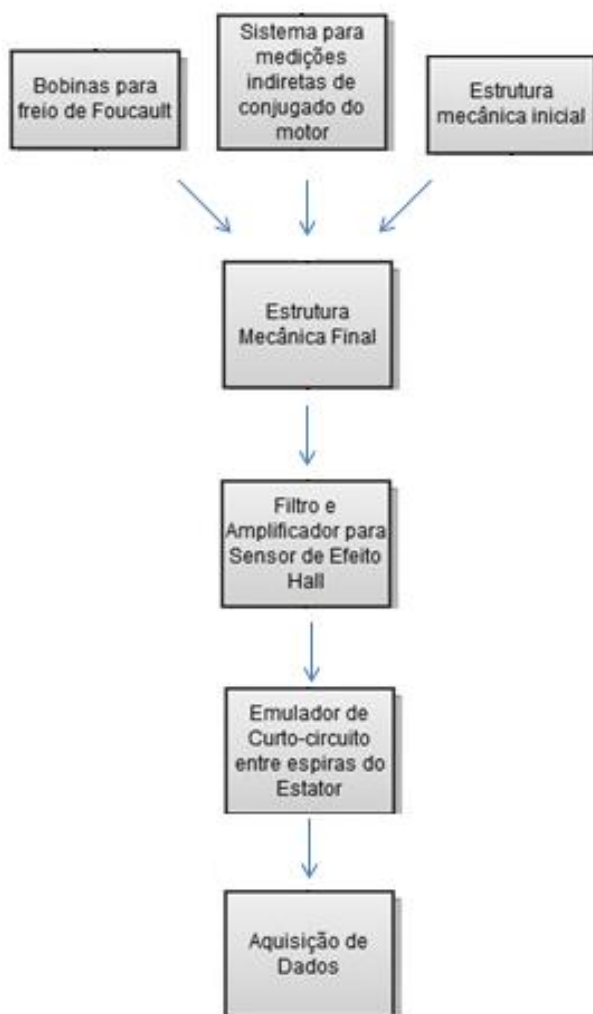


Figura 8 - Passos e Etapas Preliminares. Fonte: Autor

Para diferenciar os passos e etapas preliminares dos passos e etapas do desenvolvimento do algoritmo, estes são precedidos do prefixo “A” e aqueles são precedidos do prefixo “P”. “P” se refere à “preliminar” e “A” se refere a “algoritmo”.

### **3.4.1 ETAPA P1 - Montagem da bancada para testes com motores de indução**

Para que fossem feitas as simulações de falhas incipientes nos motores de indução trifásicos e a aquisição de dados, foi necessária a construção de uma bancada de testes, cujas partes são descritas a seguir.

#### **3.4.1.1 Passo P1 – Base Mecânica**

A construção da base mecânica se deu em dois momentos.

A estrutura mecânica inicial pode ser visualizada na Figura 9. Esta estrutura consistia de uma base de aço principal, sobre a qual estavam soldadas duas outras bases.


Uma das bases servia de apoio para o motor. Nela, o motor era apoiado de um lado por uma dobradiça e do outro por uma célula de carga.

A outra base serve para apoiar duas bobinas e dois mancais. Estes mancais servem de apoio para um eixo de aço no qual está acoplado um disco de alumínio.


As bobinas, juntamente com o disco de alumínio, são utilizadas para aplicação de cargas mecânicas no motor.

Porém, após alguns testes tentando alinhar o motor e fazer a leitura de sinais da célula de carga, e não obtendo bons resultados, a estrutura inicial teve que ser um pouco modificada.

Na nova estrutura, ao invés de o motor ser apoiado de um lado por uma dobradiça, e do outro por uma célula de carga, foi montada uma nova base rígida de aço para apoiar o motor. Isso fez com que o nível de vibrações no motor reduzisse bastante, e o alinhamento do motor com o eixo do disco de alumínio ficasse muito mais simples. Na Figura 10 é mostrada a estrutura mecânica final.



**Figura 9 - Estrutura Mecânica Inicial**  
 (1 – local para célula de carga, 2 – base do motor, 3 – dobradiça, 4 – base para mancais do eixo e bobinas, 5 – base de toda estrutura mecânica, 6 – disco de alumínio, 7 – mancal). Fonte: Autor



**Figura 10 - Estrutura mecânica final.** Fonte: Autor.

### 3.4.1.2 Passo P2 - Confeção das bobinas para o Freio de Foucault

Neste trabalho, a carga mecânica aplicada no motor é gerada por Correntes de Foucault. Esta técnica é aplicada para que não haja necessidade de mais um acoplamento, facilitando, assim, o alinhamento do motor.

Como um disco de alumínio já havia sido acoplado ao eixo apoiado por mancais, foi necessário projetar duas bobinas para gerar um campo magnético constante.

Para calcular o comprimento total do fio de cobre a ser utilizado em cada bobina, foram utilizados dois métodos e, para os dois, foi tomada por modelo uma bobina de um módulo da WEG.

Assim, baseado neste módulo, foi confeccionada uma bobina de 9000 espiras, utilizando 2000 m do fio de cobre Nº 24 da tabela AWG.

### 3.4.1.3 Passo P3 - Sistema para medições indiretas de conjugado dos motores


Na estrutura mecânica inicial, foi feito um sistema para medições indiretas de conjugado do motor através de uma célula de carga. Como foi especificado anteriormente, a base do motor foi apoiada de um lado por uma dobradiça e do outro pela célula de carga. Assim, quando o rotor do motor gira em determinado sentido, o estator aplica uma força na base e esta pressiona a célula. Esta força aplicada na célula é proporcional ao conjugado gerado no motor. Estando alimentada por uma tensão constante, a relação entre o sinal de saída e a força aplicada na célula é linear. Assim, na teoria, tratando este sinal de saída seria fácil obter uma medida de conjugado.

Para amplificar o sinal da célula de carga, foi utilizado um “amplificador de instrumentação”, pois este é utilizado para pequenos sinais e elimina ruídos de modo comum na entrada. A amplificação do circuito é definida por (FABBRO, 2002):

$$V_0 = (V_1 - V_2) \left(1 + 2 * \frac{R_2}{R_g}\right), \quad (12)$$

Sendo que,  $V_1 - V_2$  é a tensão gerada pela célula de carga, e o valor do ganho deste amplificador é definido pelos resistores com denominação  $R_g$  e  $R_2$ .

A configuração deste amplificador está representada na Figura 11. Para os resistores de valores  $R_2$  e  $R_1$ , foi definido o valor comercial de 220 k $\Omega$  e para o resistor de valor  $R_g$  foi definido um potenciômetro de 10 k $\Omega$ . Além destes valores de resistores estarem disponíveis nos laboratórios onde foi realizado este projeto, isto foi feito para que o sinal oriundo da célula de carga por conta do conjugado do motor, que é da ordem de milivolts (mV), fosse ajustado para a ordem de volts (V).



**Figura 11 - Circuito Amplificador de Instrumentação. Fonte: Fabbro (2002).**

Como, na célula de carga, o sinal de saída é contínuo e linear em relação à força aplicada a esta, e devido à proximidade desta célula em relação a um motor alimentado por um inversor de frequência, foi necessário projetar um filtro passa-baixa para que os ruídos da ordem acima de 60 Hz fossem atenuados e o sinal de saída da célula de carga, que é de frequência “0”, permanecesse constante. Neste caso, o filtro projetado foi um filtro Butterworth de 4ª ordem com frequência de corte de 50 Hz, pois a resposta deste tipo de filtro é plana nas vizinhanças do ponto de frequência “0” e atenua as frequências maiores. O ganho do filtro foi de “um”, por já haver outro circuito responsável pela amplificação do sinal.

Um Filtro Butterworth de 4ª ordem pode ser construído através da utilização de dois filtros Butterworth de 2ª ordem conectados em série. A topologia deste filtro está representada na Figura 12.




Figura 12 - Filtro Butterworth passa baixa, de ordem 2. Fonte: Pertence (1988).

As equações utilizadas para o projeto deste filtro foram retiradas do livro “Amplificadores Operacionais e Filtros Ativos” (PERTENCE, 1988) e estão listadas a seguir:

- Ordem do Filtro: quatro (dois filtros ativos de ordem dois ligados em série)
- Frequência de corte = 50 Hz
- $a = 0,765$
- $b = 1$
- $K = 1$  (ganho do filtro)
- $R_3 = R_4 = 0$
- $C_2 = 20 \text{ nF}$
- $C_1 \leq [a^2 + 4b(K - 1)] * C_2 / 4b$
- $R_1 = 2 / \{a * C_2 + [(a^2 + 4b * (K - 1)) * C_2^2 - 4b * C_1 * C_2]^2\}$
- $R_2 = 1 / [b * C_1 * C_2 * R_1 * (W_c^2)]$

Nas Figuras 13 e 14 são mostrados, respectivamente, o esquemático final do filtro e a resposta em frequência deste (curva de “ganho x frequência”).

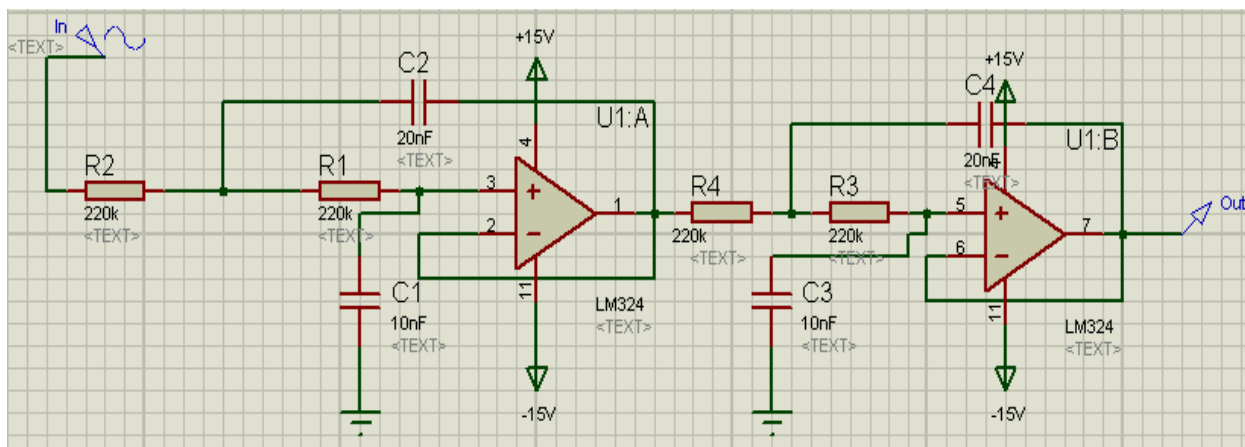


Figura 13 - Esquemático final do circuito do Filtro. Fonte: Autor.




Figura 14 - Resposta em frequência do filtro. Fonte: Autor.

No Apêndice B são mostrados o esquemático e o PCB (*printed circuit board*) da placa eletrônica desenvolvida.

Na prática não foi possível, com a estrutura mecânica inicial, obter uma boa aquisição indireta de conjugado. Como o motor estava apoiado apenas sobre uma célula de carga e uma dobradiça, o nível de vibração fazia com que o sinal de conjugado não pudesse ser lido.

Por isso, foi fabricada uma peça de aço para que o motor ficasse mais firme sobre a base principal, os ruídos diminuíssem e não mais se utilizasse a célula de carga.

Como a detecção de falhas foi *offline* (ou seja, a detecção ocorreu depois que todos os dados já haviam sido coletados do motor, não sendo necessário este estar ligado), decidiu-se utilizar outro método para mensurar a carga aplicada ao motor.

Através de estudos e da análise dos motores trifásicos de indução, pôde-se observar que as curvas tanto de conjugado em função da rotação (mostrada na Figura 15), quanto a de corrente em função da velocidade de rotação podem ser aproximadas por retas quando esta velocidade se aproxima da nominal.

Este método foi utilizado para suprir a deficiência da medição indireta da célula de carga. Assim, foram realizados os seguintes cálculos.




Figura 15 - Curva de Conjugado X Velocidade do Motor de Indução. Fonte: Fitzgerald (2006).



Primeiramente, a curva de conjugado do motor em função da velocidade do rotor, na região entre a velocidade nominal e a velocidade síncrona, foi linearizada. Para isto, utilizaram-se apenas os dois primeiros termos da série de Taylor, tomando como referência a condição de operação nominal. A expressão da equação da reta tem o formato

$$C = C_0 + M_c \omega, \quad (13)$$

onde  $C$  é p conjugado aproximado,  $C_0$  é o conjugado na velocidade nominal,  $\omega$  é a velocidade e  $M_c$  é a inclinação da reta.

Os valores de conjugado, para o motor utilizado neste projeto, nesses dois pontos de operação, são 4,16 N.m e 0 respectivamente. Assim, a estimativa de  $M_c$  é dada por

$$M_c = \frac{C - C_n}{W - W_n} = \frac{4,16 - 0}{180,12 - 188,49} = -0,4970. \quad (14)$$

Desta forma, a equação final é dada por

$$C = 93,68 - 0,497 W. \quad (15)$$

Em seguida, foi realizado o mesmo procedimento para a curva de corrente em função da velocidade do motor. Porém, as velocidades utilizadas para esta linearização foram a velocidade nominal (1720 rpm) e a velocidade na condição a vazio (1798 rpm). A corrente nominal já é fornecida pelo fabricante (1,75 A), e a corrente medida na velocidade 1798 rpm foi de 1,15 A.

A partir da linearização da corrente em função da velocidade do motor nos pontos descritos, foram obtidas as equações

$$M_i = \frac{1,15 - 1,75}{188,29 - 180,12} = -0,07344, \text{ e} \quad (16)$$

$$I = 14,978 - 0,07344 W. \quad (17)$$

Para fazer com que o conjugado fosse estimado através da medição de corrente, isolou-se a velocidade do motor na equação de corrente e este valor foi substituído na equação de conjugado. Assim, conseguiu-se uma aproximação do conjugado pelo nível de corrente do motor, pelas equações

$$W = \frac{14,978 - I}{0.07344}, \quad (18)$$

$$C = 93,68 - 0,497 \times \left( \frac{14,978 - I}{0.07344} \right) \text{ e} \quad (19)$$

$$C = 6,76 \times I - 7,68. \quad (20)$$

Para determinar se a estimativa foi feita corretamente, foram calculados alguns pontos e obtiveram-se os seguintes resultados:

- $C = 0,00 \rightarrow I = 1,15 \text{ A (estrela)} \quad 1,99 \text{ A (delta)}$
- $C = 1,04 \rightarrow I = 1,29 \text{ A (estrela)} \quad 2,23 \text{ A (delta)}$
- $C = 2,08 \rightarrow I = 1,44 \text{ A (estrela)} \quad 2,49 \text{ A (delta)}$
- $C = 3,12 \rightarrow I = 1,60 \text{ A (estrela)} \quad 2,77 \text{ A (delta)}$
- $C = 4,16 \rightarrow I = 1,75 \text{ A (estrela)} \quad 3,03 \text{ A (delta)}$


Como os valores calculados e os medidos foram bem próximos (erro máximo de 5%), esta aproximação foi considerada satisfatória.

#### **3.4.1.4 Passo P4 - Ajuste e confecção do circuito impresso amplificador para o Sensor Hall**

A grandeza física utilizada, neste projeto, para detectar falhas incipientes nos motores de indução trifásicos foram as correntes do estator deste tipo de motor. Assim, foi escolhido um sensor hall para que a tensão de saída deste fosse enviada ao sistema de aquisição (o qual lê apenas tensão). O sensor escolhido suporta até 50 A (cinquenta Amperes). Como as correntes do motor aqui utilizado são da ordem de 2 A e o sistema de aquisição de dados pode operar até uma faixa entre -10 V e +10 V, foi necessário amplificar o sinal para que esta faixa fosse melhor aproveitada.

Para isso, foi utilizado um circuito com amplificador e filtro projetado anteriormente por outro bolsista envolvido no projeto. Porém, como a placa

apresentava alguns problemas (como trilhas partidas e alguns componentes defeituosos), foi confeccionada uma nova placa com base no mesmo projeto. Na Figura 16 pode-se observar o circuito já conectado ao sensor hall e ao sistema de aquisições. O PCB do circuito amplificador utilizado e que foi previamente projetado por outro bolsista está disponibilizado no Apêndice B.



**Figura 16 - Conexão do Sensor Hall ao Circuito Amplificador. Fonte: Autor.**

(1 – circuito de filtro e amplificador; 2 e 3 – sistema de aquisição de dados; 4 – conexões para motor de indução trifásico; 5 – baterias de 9 V; 6 – Sensor de efeito Hall)

### **3.4.2 ETAPA P2 - Circuito para emular curto-circuito entre espiras do estator**

Para que as falhas por curto-circuito fossem emuladas, foi necessária a utilização de um motor rebobinado (especificado na Subseção 3.2.6). Este teve

suas três fases rebobinadas e disponíveis em alguns pontos para a aplicação do curto-circuito. A quantidade de espiras curto-circuitadas em alguns pontos é descrita na etapa P3.

Durante a aquisição de dados, foram utilizados três níveis de curto-circuito e, a cada nível, mais espiras foram curto-circuitadas. Assim, foram definidos três níveis de severidade de falha.

Na Figura 17 é mostrado o motor e os pontos disponíveis para emulação das falhas.



**Figura 17 - Motor Rebobinado com pontos disponíveis. Fonte: Autor.**

Além deste motor, foi utilizado um aparato, previamente construído, o qual, por meio de botoeiras, faz a seleção entre ausência de falhas, falhas de alta impedância e falhas de baixa impedância. Com este, apenas é possível simular o curto-circuito de uma fase do motor por vez.

O esquemático elétrico deste aparato é mostrado na Figura 18. Na parte direita desta figura, pode-se ver o circuito de comando do aparato e na parte esquerda, o circuito de força. Os botões  $b_1$  e  $b_0$  servem, respectivamente, para ligar e desligar o motor. Ao apertar o botão  $b_2$ , um curto-circuito de alta impedância é aplicado em uma das fases do motor e, ao apertar o botão  $b_3$ , um curto-circuito de baixa impedância é aplicado à mesma fase do motor.

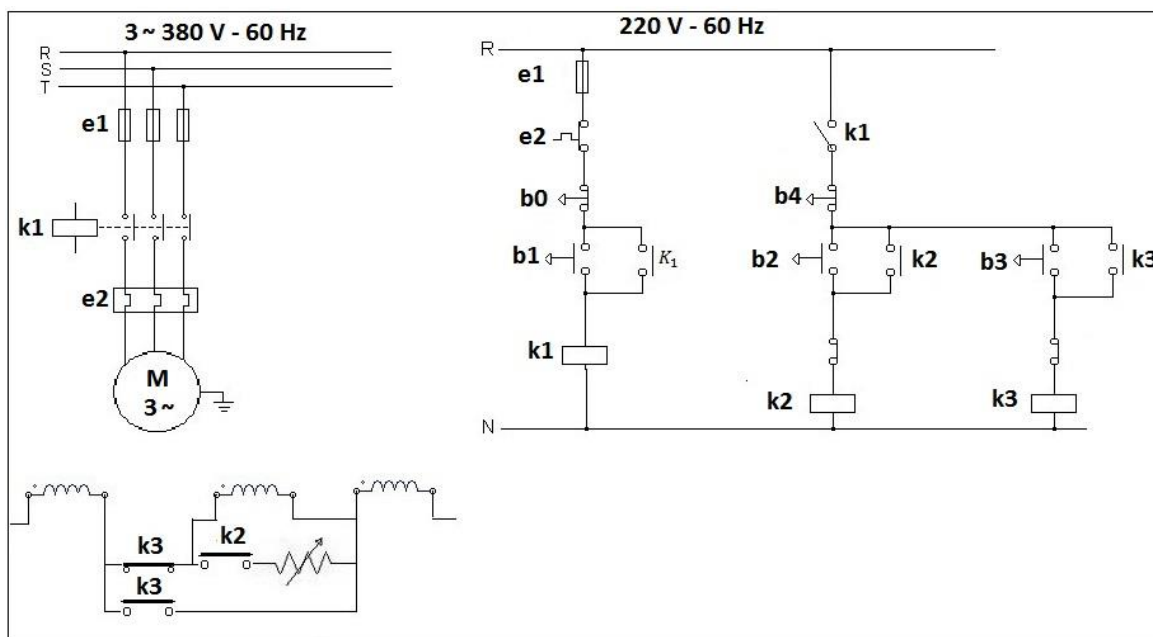


Figura 18 - Esquema do aparato para emulação de falhas. Fonte: Autor.

### 3.4.3 ETAPA P3 - Aquisição de dados

Após a montagem da bancada de testes, ocorreu a aquisição dos dados através do sistema de aquisição dos dados U2352 da Agilent®.

Para a aquisição das correntes das três fases do motor, foram utilizados os canais 1, 2 e 3 (pinos 1 2 e 3 do sistema), no modo  $\pm 5 V$  (sinais de entrada devem estar dentro dessa faixa de tensão), “Single Shot” (único disparo) e “DIFF” (neste modo, o resultado da conversão “AD” é a diferença entre o sinal de entrada de dois pinos do sistema de aquisições).

A taxa de amostragem usada foi de 10 kHz, e o período total para cada aquisição foi de 10 segundos. Assim, foram gerados sinais de 100.000 pontos.

Cada um dos sinais gerados possui 4 informações: o nível de carga aplicada, de qual fase este sinal se originou, qual a frequência do conversor e o “modo” de operação do motor. Assim, devido às diferentes combinações dessas quatro informações, foi gerado um banco de dados com 441 sinais de 100000 pontos. Estas informações estão descritas na Tabela 4.

Características dos Vetores do Banco de dados Gerado							
Nível de Carga aplicada	0%	50%	100%				
Fases utilizadas	Fase 1	Fase2	Fase3				
Frequência do Conversor	30Hz	35Hz	40Hz	45Hz	50Hz	55Hz	60Hz
Modos de operação do motor	Sem falha	ai1	ai2	ai3	bi1	bi2	bi3

**Tabela 4 – Informações dos Vetores. Fonte: Autor.**

Os termos “ai” e “bi” representam, respectivamente, alta impedância e baixa impedância. O número que está ao lado destes termos representa a severidade da falha aplicada, ou seja, quanto maior o número, maior o número de espiras de uma mesma fase que estão em curto-circuito.

O número 1 indica que aproximadamente 5 espiras (representando 1,41% do total destas) estão em curto-circuito. Já o número 2 indica que aproximadamente 17 espiras (representando 4,81% do total destas) estão em curto-circuito, e o número 3 indica que aproximadamente 32 espiras (representando 9,26% do total destas) do enrolamento de uma fase estão em curto-circuito.

Estes valores foram medidos através de ensaios previamente realizados no LPE.

### **3.5 PASSOS E ETAPAS DO DESENVOLVIMENTO DO ALGORÍTMO**

#### **3.5.1 Etapa A1 – Implementação do Algoritmo de treinamento e teste da rede Som 2-D**

Paralelamente à construção da bancada de testes, o algoritmo de treinamento, rotulação e teste da rede neural SOM 2-D foi implementado. Para validar seu funcionamento, foram desenvolvidos 3 passos, estes representados na Tabela 5.

ETAPA A1 - Implementação do Algoritmo de Treinamento e Teste		
Passo	Rede Implementada	Banco de Dados Utilizados
1	WTA	Íris
2	SOM 1-D	Íris
3	SOM 2-D	Dermatologia

**Tabela 5 – Resumo da Etapa A1. Fonte: Autor.**

### **3.5.1.1 Aplicação e teste do conceito de competitividade**

Nesse passo, a rede WTA foi implementada, pois esta se assemelha à rede SOM 2-D no quesito competitividade. Porém, não utiliza o conceito de vizinhança espacial.

Para teste do funcionamento desta rede, utilizou-se o banco de dados Íris, por este ser o mais simples dos três estudados em relação à quantidade de características e a facilidade na classificação.

As características deste banco de dados estão descritas no Apêndice A.

### **3.5.1.2 Aplicação e teste do conceito de vizinhança espacial**

Neste passo, a rede SOM 1-D foi implementada. A única diferença desta rede neural para a rede SOM 2-D é a quantidade de “dimensões” da grade fixa, sendo a rede SOM 1-D unidimensional.

Para comparar-se os resultados entre os treinamentos desta rede e da rede WTA, foram utilizados o mesmo número de neurônios e o mesmo banco de dados nos dois treinamentos.

### **3.5.1.3 Implementação da Rede SOM 2-D**

Este passo foi importante para mostrar que, além de possuir a característica de inteligibilidade, esta rede neural também é um bom classificador neural. O banco de dados dermatologia foi utilizado para testá-la, pois este possui um número maior de classes.

## **3.5.2 ETAPA A2 – Definições de Projeto e Análise dos Dados**

Para esta etapa, apenas uma parte dos sinais gerados foi utilizada. Estes sinais foram escolhidos por serem considerados “extremos” (representando 11% do total de dados):

- Frequência da tensão de alimentação do motor: 30 Hz e 60 Hz
- Porcentagem de carga aplicada: 0% e 100%.

O resumo das análises e definições é mostrado na Tabela 6.



ETAPA A2 - Análise dos Dados	
Passo	Análise
1	definição da referência de motor ideal
2	definição da faixa de espectro de frequências
3	definição das harmônicas
4	definição da quantidade de fases do motor
5	definição da frequência de amostragem
6	análise dos dados no domínio do tempo
7	análise dos dados no domínio da frequência

**Tabela 6 – Resumo da Etapa A2. Fonte: Autor.**

### **3.5.2.1 Definição da referência de motor em funcionamento ideal**

Nesse passo, houve a comparação entre os sinais do motor rebobinado desacoplado sem falha e os sinais do motor rebobinado acoplado sem falha.

Para que o motor acoplado fosse considerado referência para a detecção de falhas, seu espectro de frequências deveria ter o mesmo formato que o espectro de frequências do motor desacoplado.

### **3.5.2.2 Definição da faixa do espectro de frequências**

Para identificar a faixa de frequências a ser utilizada para obter uma identificação mais fácil das falhas, mediu-se a variância de uma parte dos dados coletados.

Para cada sinal escolhido do banco de dados, foi aplicada a transformada rápida de Fourier (FFT). De posse desses resultados, foi calculada a variância de cada frequência de saída desta transformada, e essas variâncias foram plotadas em um gráfico “Variância x Frequência”. Assim, verificou-se a faixa do espectro de frequências onde há maior variação de amplitudes.

### **3.5.2.3 Definição das harmônicas utilizadas para a detecção de falhas**

Dentro da faixa de frequências escolhida no passo anterior, verificaram-se as frequências que possuíam os maiores valores de variância. A técnica utilizada foi semelhante à do passo anterior: plotando um gráfico “Variância x Frequência” para cada frequência de saída da transformada de Fourier.



Para cada valor de frequência da fonte de tensão que alimenta o motor, o espectro de frequências da corrente do estator se modifica, pois as frequências que apresentam as maiores variâncias são múltiplas da frequência da tensão de alimentação, também chamadas harmônicas. Assim, foi necessário definir as harmônicas que seriam retiradas do espectro de frequências para serem apresentadas à rede neural.

#### **3.5.2.4 Definição da quantidade de fases necessárias para a detecção de falhas**

Outra análise realizada foi em relação à quantidade de fases necessárias para a detecção de falhas. A escolha da faixa do espectro de frequências a ser utilizada foi feita inicialmente através da leitura de dados de três fases do motor. Se a variância das componentes de frequência dos dados de apenas uma fase tivesse um valor relevante, a detecção da falha através de uma fase poderia ser tão efetiva e mais simples que a detecção através de três fases.

Visto que o curto-circuito é aplicado em apenas uma fase do motor e devido ao tipo de conexão elétrica utilizada neste (delta), as amplitudes das harmônicas de duas fases da fonte de alimentação deste motor são iguais.

#### **3.5.2.5 Definição da frequência de amostragem**

Outro ponto analisado foi a frequência de amostragem na aquisição de dados. Inicialmente, a frequência utilizada para a aquisição de dados foi de 10 kHz, por isso, pôde-se obter um espectro de frequências de 0 a 5 kHz. Contudo, como na subseção 3.5.2.2 foi definida uma menor faixa do espectro de frequências a ser utilizada na detecção de falhas, foi preciso analisar uma frequência de amostragem menor, pois, se a detecção pudesse ser feita a uma frequência de aquisição menor, um sistema em tempo real pode ser mais facilmente implementado futuramente.

### 3.5.2.6 Análise das curvas de correntes no domínio do tempo

Para verificar a consistência da aquisição dos dados, também foram verificadas as curvas dos sinais de correntes no domínio do tempo. Para isso, foram colocadas no mesmo gráfico, a corrente de uma das fases do motor em quatro estados: ausência de falhas, e três níveis crescentes de curto-circuito (1,41%, 4,8% e 9,26% de espiras de uma fase do motor).

Todos esses estados foram mostrados com a frequência de 50 Hz. Também foram comparadas as curvas com e sem aplicação de carga.

### 3.5.2.7 Análise dos dados no domínio da frequência e determinação da quantidade de neurônios utilizados na rede neural

Neste passo, através do estudo dos dados e de uma metodologia aplicada, definiu-se a quantidade de neurônios utilizados na rede SOM 2-D.

### 3.5.3 ETAPA A3 – Treinamento, teste, ajustes e configuração final do algoritmo neural com dados de curto-circuito

Nesta etapa do projeto, foram feitos inúmeros testes e ajustes para que o algoritmo implementado inicialmente se adaptasse ao problema proposto. Todos os passos realizados aqui estão resumidos na Tabela 7.

ETAPA A3 - Treinamento, Testes e Ajuste da Rede Som Matricial		
Passo	Treinamento	Classificação
1	Função Gaussiana desde o Início	entre baixa ou alta impedâncias, ou normal
2	Vizinhança topológica variável	entre baixa ou alta impedâncias, ou normal
3	Vizinhança topológica variável	entre normal ou com falhas
4	Vizinhança topológica variável	entre normal ou com falhas de alta impedância
5	Vizinhança topológica variável	entre normal ou com falhas de baixa impedância
6	Ajuste Final do Algoritmo	x

**Tabela 7 – Resumo da Etapa A3. Fonte: Autor.**

O número total de vetores de características utilizados foi de 294: 147 de uma das fases do conversor que alimenta a fase em curto-circuito do motor e 147 da fase do conversor que não alimenta a fase em curto-circuito do motor. Isto representou 66,6% dos dados.

Duas normalizações foram feitas para que nenhuma das características influenciasse mais que as outras no resultado final da classificação. Primeiramente, a normalização foi feita através de

$$x = \frac{x - \mu}{\sigma}, \quad (21)$$

onde  $x$  é um atributo qualquer dos vetores de características, e  $\mu$  e  $\sigma$  são, respectivamente, a média e o desvio padrão deste atributo para todos os vetores de características do banco de dados.

A partir do treinamento e teste 2 (Subseção 3.5.3.2), antes dessa normalização, foi realizada uma normalização inicial, na qual cada harmônica foi dividida pela frequência fundamental. Isto foi feito para que, teoricamente, o nível de carga não influísse na classificação das falhas.

Além disso, foi utilizado um total de 30 neurônios: uma grade fixa de 6 linhas por 5 colunas de neurônios (definido na Seção 4.2.7), e a função de aprendizagem utilizada foi mostrada na Equação 8.

Também, percebeu-se, depois de alguns treinamentos realizados, que não era necessário mais do que 20 épocas para o erro de treinamento se estabilizar. Assim, foi utilizada esta quantidade de épocas durante o treinamento.

Do passo 1 ao passo 5 desta etapa, a rotulação dos neurônios foi feita através da seguinte lógica:

Após o treinamento, todos os dados de treinamento eram apresentados novamente à rede neural e verificava-se a quantidade de vezes que cada neurônio era considerado “vencedor” (ou seja, tinha seu vetor de características mais próximo ao vetor de características de entrada) para cada classe de vetores de entrada.

Se um neurônio era considerado mais vezes “vencedor” para vetores de entrada da classe de motores em funcionamento normal, este neurônio era rotulado como representante da classe de motores em funcionamento normal.

Porém, se houvesse empate no número de vezes que um neurônio era considerado vencedor para duas classes de vetores de entrada, este neurônio não era rotulado para nenhuma classe.

Por fim, para cada passo desta etapa, foram realizados 10 treinamentos e testes.

Em metade destes, foram utilizados 220 vetores de características aleatórios para o treinamento, e 74 para testes. Isso foi feito para verificar a capacidade de generalização da rede a partir de 75% dos dados para treinamento e colocando 25% de dados diferentes para verificar a quantidade de acertos. Na outra metade, foram utilizados 30 vetores de características de cada classe (90 vetores no total) para treinamento e, após isso, todos os outros vetores foram utilizados para teste. Isto foi feito para verificar se, mesmo sem manter a proporção real de dados, a rede neural conseguiria manter uma taxa elevada de acerto na classificação dos dados.

Ao fim de cada teste foi gerada uma “matriz de confusão”. Nesta matriz, as linhas representam a qual classe pertence o dado que foi apresentado à rede neural e as colunas representam qual foi a classificação deste dado por parte da rede neural. Esta matriz serviu para mostrar quais dados eram mais facilmente classificados corretamente ou não pela rede.

#### **3.5.3.1 Treinamento e teste 1 – Vizinhança variável desde o início do treinamento.**

Nesse passo, para utilizar o conceito de vizinhança espacial, foi utilizada a Equação 10 desde o início do treinamento, e inicialmente a vizinhança topológica foi de 4. Com esta equação, quanto mais distante espacialmente o neurônio for do neurônio vencedor, menor será a atualização do seu peso. Além disso, o número de neurônios vizinhos topologicamente é sempre constante, porém a atualização dos pesos destes diminuía de acordo com o número de iterações, ou seja, de acordo com as interações dos neurônios com cada vetor de característica que aparece na rede.

O teste foi realizado tentando classificar os dados entre 3 classes: motor com ausência de falhas, motor com falha de curto-circuito de alta impedância e motor com falha de curto-circuito de baixa impedância.

### **3.5.3.2 Treinamento e teste 2 – Vizinhança variável depois de determinadas iterações**

Similarmente ao passo anterior, o número inicial de neurônios vizinhos foi de 4 neurônios. Porém, não mais foi utilizada a equação 10 desde o início do treinamento. Até a décima época, tanto o neurônio vencedor quanto os seus vizinhos tinham os seus pesos atualizados com uma função vizinhança de valor constante e igual a “1” (função retangular), porém o número de vizinhos ia decrescendo.

Na primeira e na segunda época, a vizinhança espacial foi de 4 neurônios. Já na terceira e quarta épocas, o número de vizinhos foi reduzido a 3. Na quinta e sexta épocas, o número de neurônios vizinhos foi de 2. Por fim, a partir da sétima época, o número de vizinhos foi reduzido a 1.

O teste realizado aqui classificou os dados nas mesmas três classes do passo anterior.

### **3.5.3.3 Treinamento e teste 3 – Teste modificado: classificação apenas entre motores com ou sem falhas**

Nesse passo, a lógica de treinamento foi igual a do passo anterior, porém o teste e classificação foram modificados. Os dados não mais foram classificados entre as 3 classes, mas sim entre duas: motor com falhas por curto-circuito entre espiras do estator ou motor em funcionamento normal.

### **3.5.3.4 Treinamento e teste 4 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de alta impedância ou com ausência de falhas.**

Esse treinamento foi realizado do mesmo modo que os dois passos anteriores, e os dados foram testados e classificados entre dados com ou sem falhas por curto circuito no estator, contudo o conjunto de vetores de características foi reduzido para este treinamento.

Nesse passo, os vetores de características que possuíam dados de curto circuito de baixa impedância foram removidos e não mais utilizados nem nos treinamentos, nem nos testes.

Assim, a quantidade de vetores de características utilizados neste passo foi de 168.

Isso foi feito para verificar se o algoritmo classificava bem os dados entre motores com ou sem falhas de alta impedância, ou seja, se este conseguia detectar o início da falha.

#### **3.5.3.5 Treinamento e teste 5 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de baixa impedância ou com ausência de falhas.**

O treinamento e o teste neste passo foram realizados do mesmo modo que o passo anterior. Porém, o conjunto de dados também foi modificado.

O conjunto de dados utilizado englobou os dados de motores com falhas de baixa impedância e motores sem falhas. Isso fez com que a quantidade de vetores de características utilizados fosse de 168 vetores.

Esta ação foi realizada para verificar se o algoritmo também classificava bem os motores entre funcionamento normal e falhas de baixa impedância

#### **3.5.3.6 Ajuste e Configuração final do algoritmo para detecção de falhas**

Neste último passo, para tentar melhorar os resultados tanto visualmente (na distribuição da grade de neurônios) como no acerto de classificação, uma lógica a mais foi implementada na rotulação dos neurônios.

Se determinado neurônio for considerado vencedor a mesma quantidade de vezes para mais de uma classe de vetores de entrada, calcula-se a distância quadrática média entre este neurônio e os vetores para os quais ele foi considerado vencedor. Assim, este neurônio era rotulado como representante da classe de vetores para os quais há a menor distância quadrática média.

Depois de obtidos os resultados, foram feitos os ajustes finais nos parâmetros do algoritmo para que os melhores resultados fossem atingidos. Os ajustes foram feitos tanto com os dados de treinamento como com os dados de teste.

A seguir, são apresentados e analisados os resultados referentes aos passos e etapas de desenvolvimento do algoritmo para a detecção de falhas.

## **4 CAPÍTULO 4 – RESULTADOS: APRESENTAÇÃO E ANÁLISE**

### **4.1 RESULTADOS DA ETAPA A1 – Implementação do algoritmo de treinamento e teste da rede SOM 2-D**

Neste tópico são mostrados os resultados dos algoritmos de teste e treinamento das três redes neurais com bancos de dados disponibilizados na internet. As características destes bancos de dados estão disponíveis no Apêndice A.

#### **4.1.1 Resultados da aplicação e teste do conceito de competitividade**

Neste passo, o conjunto de dados utilizados foi o banco de dados Íris, e a rede neural implementada foi a rede WTA.

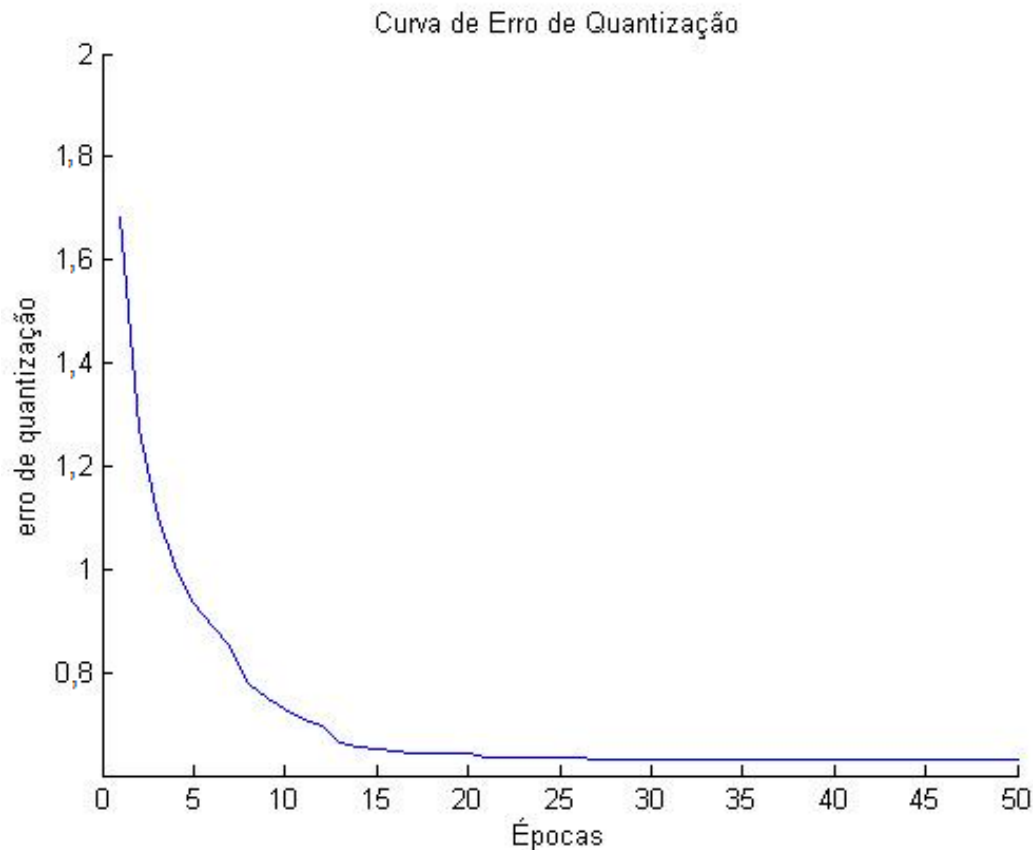
Para validar o funcionamento dessa rede neural verificou-se, primeiramente, o gráfico do erro de quantização em função do número de épocas. Este erro é a distância entre o vetor de pesos dos neurônios vencedores da “época corrente” e o vetor de características dos dados, já normalizados, utilizados para treinamento.

Com isso pôde-se constatar que este erro diminuía em função do número de épocas e convergia para um valor constante, mostrando que os neurônios se distribuíam entre os dados e se estabilizavam.

O erro não zera totalmente pelo fato de que os neurônios são apenas uma representação do conjunto total de dados. O erro só poderia se igualar a zero se para cada dado apresentado à rede, durante o treinamento, houvesse um neurônio. Assim, a curva de erro durante o treinamento, utilizando o banco de dados IRIS, é representada na Figura 19.

Para evidenciar a distribuição dos neurônios na massa de dados, foram plotadas algumas projeções bidimensionais. Para fazer estas projeções, duas características específicas do conjunto de dados são escolhidas, e cada uma delas representa 1 eixo do gráfico. Assim, durante o treinamento, pode-se observar a evolução dos pesos dos neurônios em função dessas características.

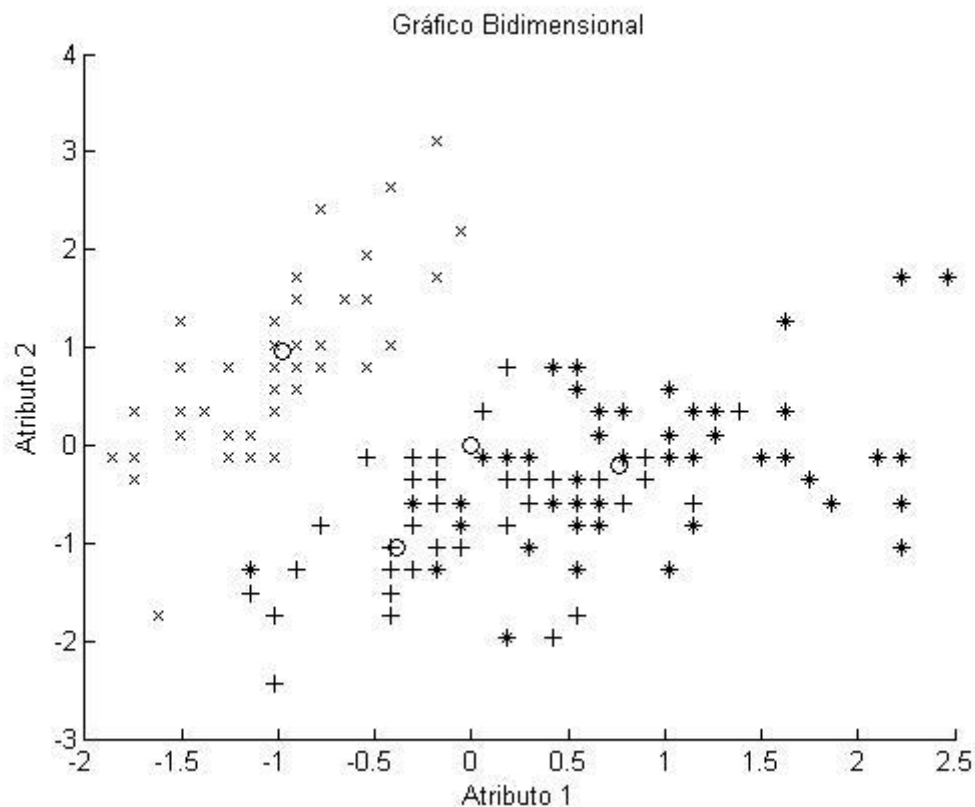
Nas projeções bidimensionais aqui mostradas, os símbolos “x”, “+” e “\*” representam dados de cada uma das classes, e os círculos não preenchidos representam os pesos dos neurônios. Uma representação bidimensional de dados do banco de dados Íris está representada na Figura 20. Nesta figura, o eixo horizontal representa o atributo “largura da sépala” e o eixo vertical representa o “comprimento da sépala”.



**Figura 19 - Erro x épocas. Fonte: Autor.**

Os melhores resultados (maior taxa de acerto) em função da quantidade de neurônios se deram quando foram utilizados sete neurônios para treinamento.





**Figura 20 - Distribuição espacial dos neurônios. Fonte: Autor.**


#### **4.1.2 Resultados da aplicação e teste do conceito de vizinhança espacial**

Assim como no treinamento da rede WTA, o erro de treinamento da rede SOM 1-D convergiu para um valor menor que o erro inicial. Porém, a curva de erros em função do número de épocas foi mais inconstante. Isto se deu pela ordem em que os dados foram apresentados à rede e pela forma que os pesos dos neurônios são atualizados.

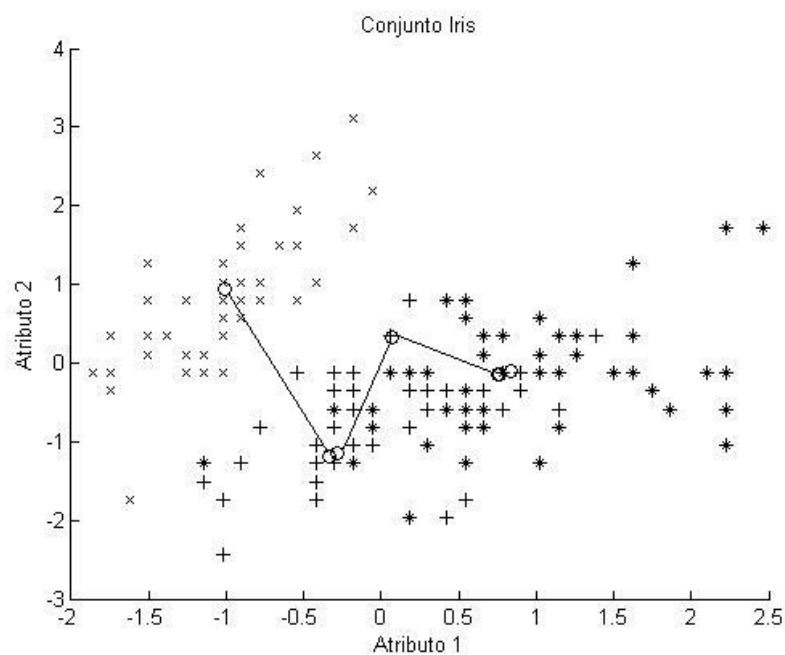
Nessa rede neural, não apenas o neurônio vencedor tem seus pesos atualizados, mas, também, todos os seus vizinhos. Isso faz com que os neurônios demorem mais para se estabilizar no conjunto de dados, pois, além destes neurônios terem que representar discretamente os dados (reduzindo o erro médio quadrático), estes têm que manter uma vizinhança espacial.

A vizinhança espacial é mantida pelo fato de que a posição dos neurônios acaba sendo um indicativo de características intrínsecas da rede (HAYKIN, 2001).

Na Figura 21 é mostrado o erro de quantização de treinamento (reduzindo até se estabilizar) em função do número de épocas, e na Figura 22 é mostrada a distribuição espacial dos neurônios (com a vizinhança espacial sendo representada por linhas) em relação a duas características do conjunto de dados.



**Figura 21– Erro em função do número de épocas. Fonte: Autor.**



**Figura 22 - Distribuição espacial dos neurônios. Fonte: Autor.**

### 4.1.3 Resultados da implementação da rede SOM 2-D

Neste passo, foi utilizado o banco de dados dermatologia, que possui 6 classes distintas, para o treinamento e teste da rede SOM 2-D.

Foi utilizada também uma grade fixa de 7x7 neurônios para treinamento e testes.

Uma parte dos dados (75%) foi utilizada para treinamento da rede e 25% foi utilizado para o teste desta. A taxa de acerto no teste foi de 97,8% e a grade fixa de neurônios depois do treinamento está representada na Figura 23, onde cada posição do gráfico representa um neurônio e cada símbolo representa uma classe distinta.

Nessa figura também pode ser observado que cada classe ficou representada em uma região específica da grade de neurônios. Esse resultado, juntamente com a alta taxa de acerto mostrou que a rede SOM pode aproximar funções com precisão arbitrária (ZANG, 2000).




Figura 23 - Grade fixa de neurônios. Fonte: Autor.

## 4.2 RESULTADOS DA ETAPA A2 – Análise dos dados

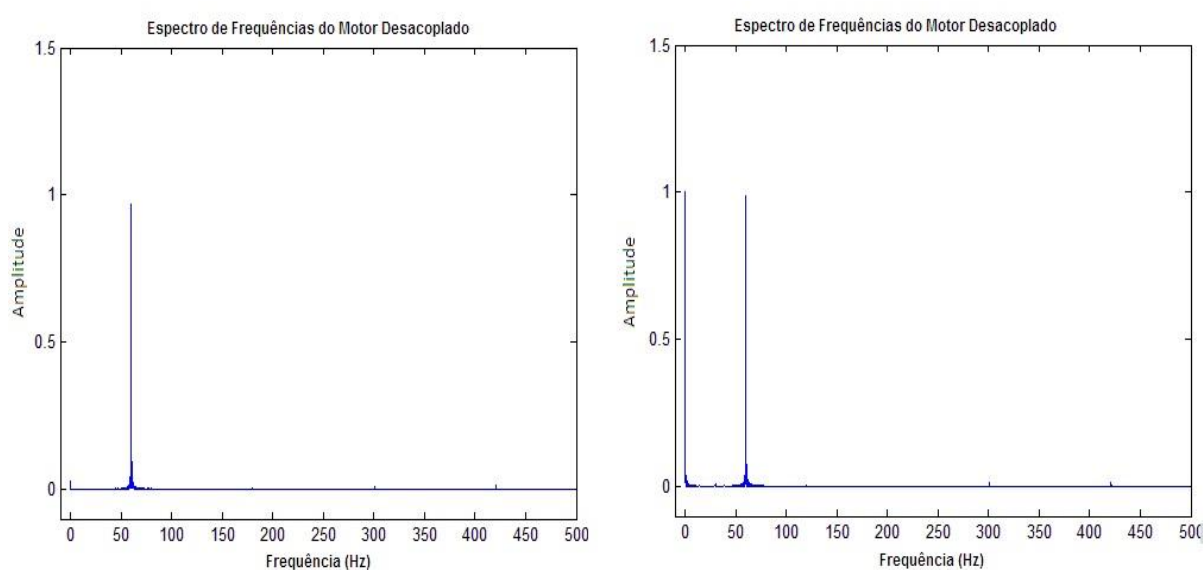
### 4.2.1 Resultados da definição da referência de motor em funcionamento ideal

Era esperado que os espectros de frequências do motor estando ou não acoplado mantivessem o mesmo formato e isso se confirmou. Porém mesmo sem a aplicação de carga por correntes de Foucault, o módulo da corrente do motor aumentou. Isto ocorreu porque o eixo com o disco de alumínio possui certa massa que deve ser movida pelo motor.

Com isso, o motor tomado como referência de funcionamento ideal foi o motor rebobinado, acoplado e sem emulação de falhas por curto-circuito.

A amplitude da parte cc do sinal também se modificou. Isto ocorreu porque o potenciômetro de ajuste do nível cc é instável e a aquisição de dados foi realizada em dias diferentes.

Na Figura 24 são mostrados os espectros de frequência lado-a-lado do motor, estando ou não acoplado. Já na Figura 25, para uma melhor visualização, esses dois espectros estão plotados no mesmo gráfico, estando o espectro de frequências do motor acoplado deslocado de 20Hz e o espectro de frequências do motor desacoplado está indicado com setas.



**Figura 24 - Espectro de Frequências do motor desacoplado e acoplado 1. Fonte: Autor.**

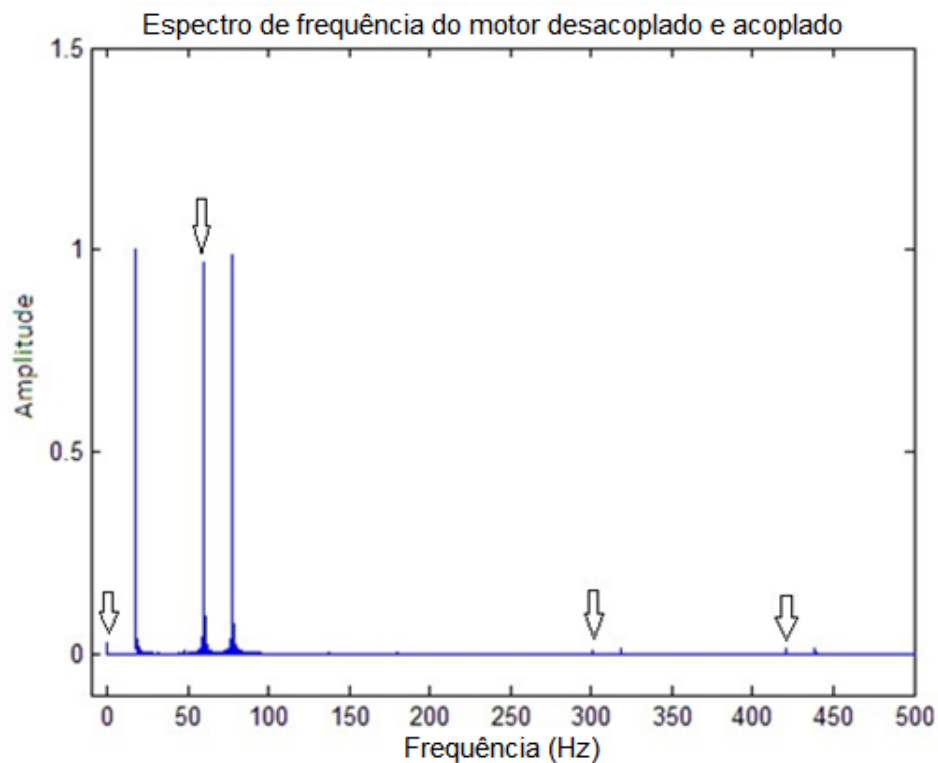



Figura 25 - Espectro de frequências do motor desacoplado e acoplado 2. Fonte: Autor.

#### 4.2.2 Resultados da definição da faixa do espectro de frequências

Através de uma análise visual de todas as variâncias das frequências de saída da função FFT plotadas em um gráfico, detectou-se que os maiores valores de variância estavam na faixa de frequências de 0 a 500 Hz.

O gráfico destas variâncias é mostrado na Figura 26.



**Figura 26 - Variância de cada frequência de saída da função FFT. Fonte: Autor.**

#### **4.2.3 Resultados da definição das frequências harmônicas utilizadas para a detecção de falhas**

Como no passo anterior, através de uma análise visual de todas as variâncias das frequências de saída da FFT plotadas em um gráfico (Figura 26), verificou-se que as harmônicas mais importantes (em função da variância) foram: fundamental, 2<sup>a</sup>, 3<sup>a</sup>, 5<sup>a</sup> e 7<sup>a</sup>.

A frequência fundamental serviu para normalizar os dados para que, teoricamente, o nível de carga não influísse na detecção da falha. Assim, antes de serem apresentadas à rede neural, as frequências harmônicas de ordem superior a “1” são divididas pelo módulo da frequência fundamental.

Além destas, também se observou que mais três outras frequências possuíam variâncias significativas: a fundamental (que serviu para normalizar os dados), a frequência de valor  $1,5f_1$  (1,5 vezes a frequência fundamental) e a frequência de valor  $0,5f_1$  (0,5 vezes a frequência fundamental).

Também foram observadas algumas frequências com valores de variância relevante que apareceram bem próximas às harmônicas. Porém estas foram desconsideradas, visto que Joksimovic e Penman (2000) demonstraram que nenhuma frequência nova no espectro de frequências do motor aparece como consequência de falha no bobinamento estático e estas também não eram previstas na Equação 2 (PENMAN, 1994).

Definidas essas frequências e através do banco de dados de vetores de correntes do estator no domínio do tempo, foi feita uma matriz com o mesmo número de vetores (441). Porém, cada um destes contendo 4 informações (Subseção 3.4.3) e 7 atributos para serem utilizados no treinamento e teste do algoritmo neural. Estes atributos são, respectivamente:  $f_1$  (frequência fundamental),  $2f_1$  (2ª Harmônica),  $3f_1$  (3ª Harmônica),  $5f_1$  (5ª Harmônica),  $7f_1$  (7ª Harmônica),  $0,5f_1$  (0,5 vezes a frequência fundamental),  $1,5f_1$  (1,5 vezes a frequência fundamental). Já as informações são o tipo da falha (ausência, baixa ou alta impedância), gravidade da falha (de acordo com a porcentagem de espiras em curto-circuito), frequência de alimentação (do conversor de frequência), porcentagem de carga aplicada.

Os sete atributos são utilizados para o treinamento da rede; já as quatro informações são utilizadas tanto para haver uma descrição de cada vetor como para o teste da rede.

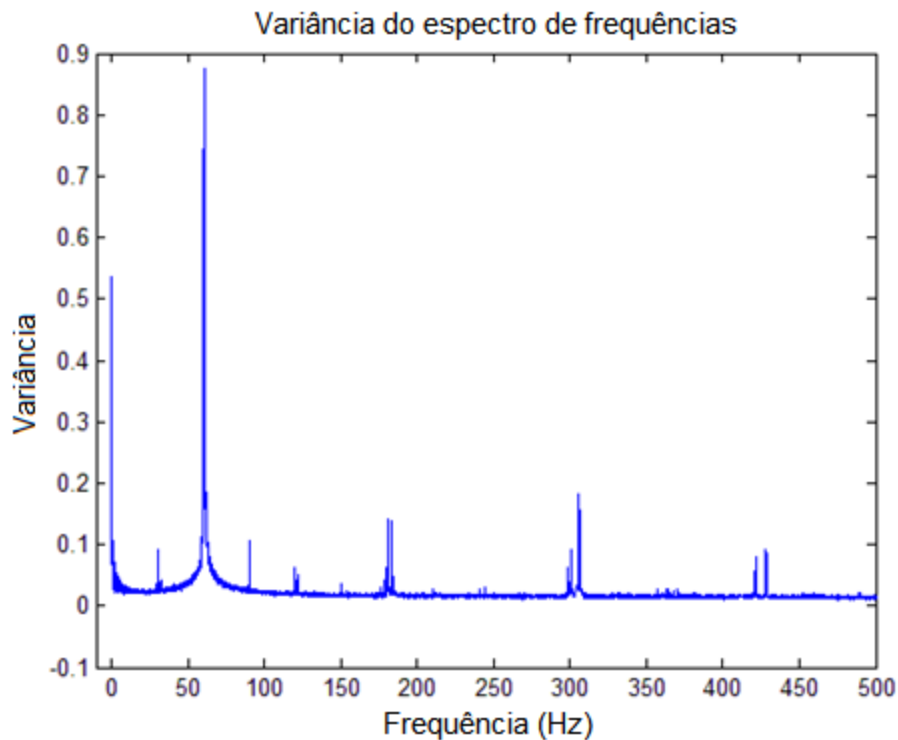


Figura 27 – Variância do espectro de frequências. Fonte: Autor.

#### 4.2.4 Resultados da determinação do número de fases necessárias

Neste passo utiliza-se a mesma técnica de plotar o valor da variância de cada frequência de saída da FFT do passo anterior. Porém, dessa vez, os valores das variâncias das frequências das harmônicas determinadas no passo anterior foram verificados não só visualizando o gráfico, mas coletando os valores destas variâncias.

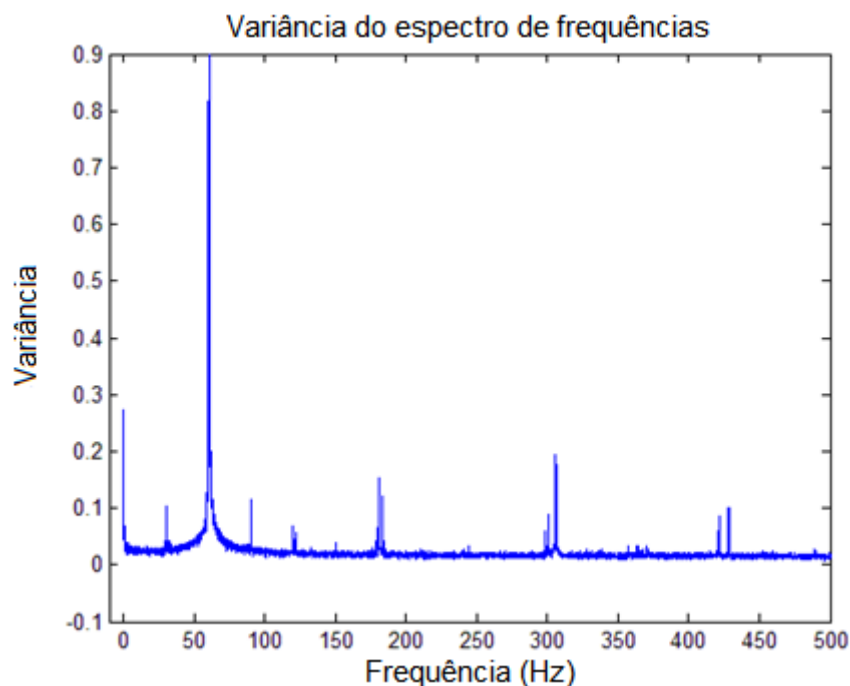
Verifica-se primeiramente o valor das variâncias das harmônicas com a utilização de dados das três fases do motor. Os valores das variâncias das harmônicas ficaram entre 0,12 e 0,18.

Em seguida, foram verificadas as variâncias com a utilização de dados de cada fase separadamente, e o valor destas variâncias se modifica muito pouco (ficaram entre 0,10 e 0,17). Na Figura 28 é mostrado o gráfico das variâncias x frequências de saída da FFT.

Assim, pode-se concluir que a detecção poderia ser feita através apenas de uma fase.



Não havendo a necessidade de utilizar informações de todas as fases, são utilizados apenas vetores de duas fases: uma fase que alimenta a fase em curto-circuito do motor e uma fase que não alimenta a fase em curto-circuito do motor. Isto foi feito pelo fato de que as amplitudes das harmônicas de duas fases do motor são iguais, não havendo necessidade de utilizar estes dois dados para treinamento e teste da rede neural.



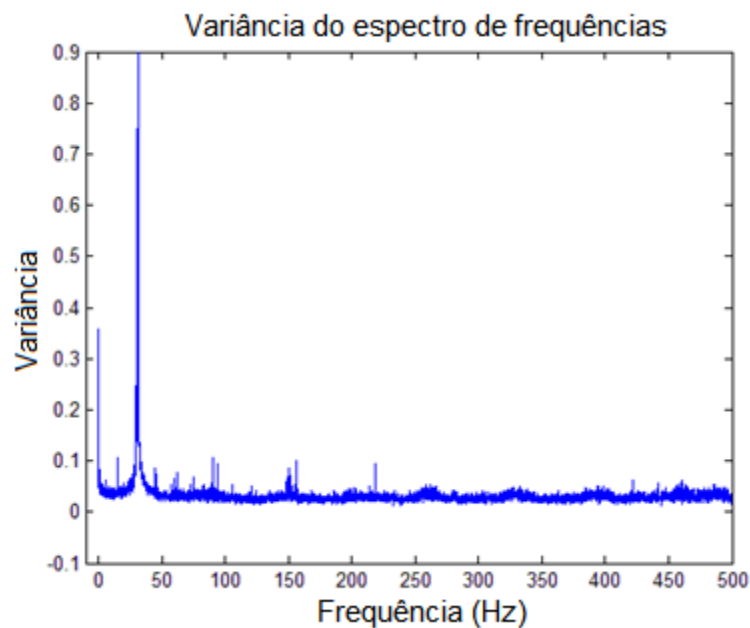
**Figura 28 - Variância dos espectros de frequência utilizando apenas uma fase do motor.**  
**Fonte: Autor.**

#### **4.2.5 Resultados da definição da frequência de amostragem**

Como a faixa de frequência utilizada nesse projeto foi definida de 0 a 500 Hz (Subseção 4.2.2), avaliou-se a possibilidade de utilização de uma frequência de amostragem de 1 kHz.

Assim como no passo anterior, os valores das variâncias das harmônicas escolhidas na Subseção 4.2.3 são medidos. Com esta frequência de amostragem de 1 kHz, os valores de variância das frequências harmônicas ficaram entre 0,09 a 0,13, ou seja, de 25 a 30% menores do que os valores obtidos com 10 kHz. Esses valores são representados na Figura 29.

Por isso, nesse trabalho, a frequência de amostragem escolhida foi de 10 kHz, para facilitar a detecção das falhas.

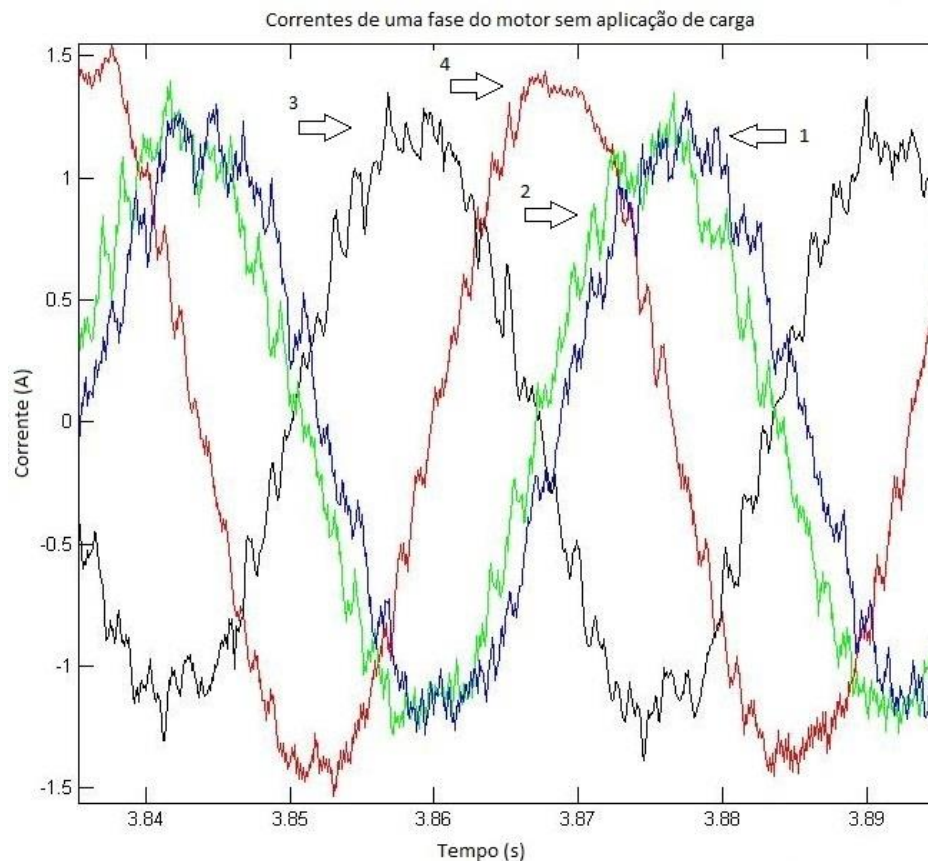


**Figura 29– Variância dos espectros de frequências com amostragem de 1 kHz, utilizando 3 fases do motor. Fonte: Autor.**

#### **4.2.6 Resultados da análise das curvas de correntes no domínio do tempo**

Quando não havia aplicação de carga, a corrente da fase do motor aumentava de acordo com a severidade do curto-circuito. Isso ocorreu porque, como a impedância do enrolamento diminui devido ao curto-circuito, a corrente desta fase aumenta. Na Figura 30 podem ser vistos, respectivamente, os sinais de corrente do estator de um motor sem falhas, com falha de “severidade 1”, “com falha de severidade 2” e “com falha de severidade 3” (numerados de 1 a 4).

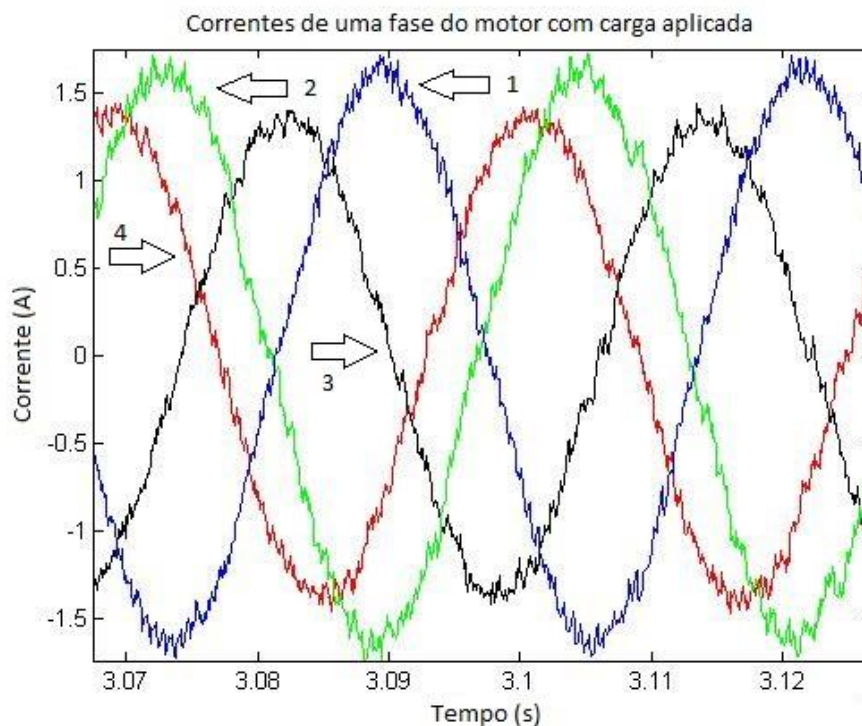
Porém, quando a carga foi aplicada, o comportamento foi contrário ao resultado da análise das correntes na ausência de carga, na qual o módulo da corrente aumentava em função da evolução da falha. Esse comportamento se deve ao tipo de carga aplicada neste projeto.



**Figura 30 - Sinal de corrente do estator sem a aplicação de carga Fonte: Autor.**

Devido à perda de força magneto-motriz no motor, a velocidade do motor diminuiu. Com isso, como a frenagem por parte das “Correntes de Foucault” é proporcional à variação de fluxo no disco metálico (ou seja, proporcional à velocidade do motor), a carga incidente no motor reduz com o aumento da severidade do curto-circuito e, conseqüentemente, o sinal de corrente também diminui.

Na Figura 31 estão representados os sinais de corrente do estator do motor de indução com carga aplicada em seu eixo. A numeração dos sinais desta figura é semelhante a da Figura 30.



**Figura 31 - Sinais de corrente do estator com aplicação de carga. Fonte: Autor.**

#### **4.2.7 Resultado da análise dos dados no domínio da frequência e determinação da quantidade de neurônios utilizados na rede neural.**


Após a definição da referência de motor ideal, das harmônicas utilizadas na detecção e das fases utilizadas para a construção do banco de dados, foram analisados visualmente alguns gráficos bidimensionais do banco gerado.

A partir desta análise, foi observado que os dados de cada classe não se agrupavam em regiões espacialmente distintas, ou seja, não se conseguiu definir facilmente um padrão.


Assim, a dificuldade na detecção de padrões faz com que uma rede neural seja uma potencial ferramenta para detecção destes, visto que, segundo Zang (2000) as redes neurais podem modelar as complexas relações do mundo real.

Na Figura 32 é mostrado um gráfico bidimensional de um conjunto com dados de motor em funcionamento normal (representado por triângulos) e motor com falhas de alta impedância (representados por pontos).

Já na Figura 33, é mostrado um conjunto com dados de motor em funcionamento normal (novamente representados por triângulos) e motor com falhas de baixa impedância.



**Figura 32 - Motor em funcionamento normal ou com falha de alta impedância. Fonte: Autor.**



**Figura 33– Motor em funcionamento normal ou com falha de baixa impedância. Fonte: Autor.**

Através destes, pode-se concluir que os dados de motor em funcionamento normal são bem mais próximos dos dados de falha com alta impedância que dos dados de baixa impedância.

Para ser determinada a quantidade de neurônios a ser utilizada para a detecção de falhas, utiliza-se a seguinte metodologia:

Primeiramente, separa-se o banco de dados em três: um conjunto de dados somente com dados do motor em funcionamento normal, outro somente com dados do motor com falhas de baixa impedância e outro com dados de falhas de alta impedância.

Em seguida, foram utilizadas determinadas quantidades de neurônios separadamente para cada banco de dados para serem treinados com o algoritmo da rede WTA. Por exemplo, dois neurônios foram treinados pelo banco de dados com dados de motor em funcionamento normal, dois outros foram treinados pelo banco de dados com dados de falhas de baixa impedância e dois outros neurônios treinados pelo banco de dados com dados de falhas de alta impedância. Cada treinamento foi interrompido quando o erro médio quadrático se estabilizava.

Depois que os neurônios são treinados separadamente, estes são reunidos e utilizados para classificar o banco de dados inicial com dados das três classes.

Na Tabela 8 é mostrado o acerto médio na classificação pelo número de neurônios utilizados. Para cada linha desta tabela, foram feitos 10 treinamentos para ser obtido o acerto médio.

Através desta, pode-se concluir que os maiores acertos médios obtidos foram ao se utilizar 6, 12 ou 30 neurônios.

Com 6 ou 12 neurônios, praticamente todos os dados eram classificados como falhas (cerca de 95%). Porém, como um dos objetivos deste trabalho é classificar os dados entre motores com ou sem falhas, estas quantidades de neurônios não eram a escolha mais indicada.

No caso da utilização de 30 neurônios, o acerto geral na classificação foi menor, porém houve um maior índice de acerto ao se apresentar um dado de motor sem falhas (25% de acerto médio na classificação).

Com isso, decidiu-se utilizar, para a rede SOM 2-D, 30 neurônios para classificar os dados, ou seja, uma grade de 6x5 neurônios.

Quantidade de Neurônios por classe			Acerto	Desvio
Normal	Alta Imp.	Baixa Imp.		Padrão
2	2	2	75,25%	8,20%
4	4	4	74,50%	10,26%
6	6	6	60%	9,48%
8	8	8	63%	10,21%
10	10	10	67%	10,23%
12	12	12	64,50%	11,71%
14	14	14	62%	12,05%
16	16	16	60,30%	11,92%

**Tabela 8 – Definição da Quantidade de Neurônios Utilizados. Fonte: Autor.**

Essa quantidade de neurônios representa 10,2% do total de vetores de características do banco de dados utilizados.

Se a rede for utilizada futuramente para uma determinada aplicação, com um processador, para detecção de falhas em motores, a redução de elementos do conjunto de dados (30 elementos representando 294) representará um ganho significativo em tempo de processamento.

### **4.3 RESULTADOS DA ETAPA A3 - Treinamento, teste e ajuste do algoritmo neural com dados de curto-circuito.**

#### **4.3.1 Resultados do treinamento e teste 1 – Vizinhaça variável desde o início do treinamento.**

Em relação à classificação, neste passo, a rede neural obteve os seguintes resultados decorrentes de 10 treinamentos:

- Acerto Médio: 48,36%
- Acerto Máximo: 55,40%
- Acerto Mínimo: 43,24%
- Desvio Padrão: 03,32%

Alguns fatores contribuíram para este baixo índice de acerto. Primeiramente, porque a classificação dos dados foi entre 3 classes: ausência de falhas, falhas de baixa impedância e falhas de alta impedância. E grande parte do erro decorreu do fato de a rede neural não conseguir distinguir dados com falhas de alta impedância e dados com falhas de baixa impedância.

Além disso, a técnica para atualização dos pesos durante o treinamento contribuiu para este baixo acerto (equação 8), visto que esta fazia com que neurônios vizinhos ao vencedor tivessem seus vetores de pesos atualizados diferentemente deste desde o início do treinamento. Isso fez com que os neurônios se “misturassem” na massa de dados. Assim, a função de treinamento foi modificada nos passos posteriores a este.

Como o índice de acerto não estava satisfatório, equilibraram-se os dados tanto no treinamento quanto no teste. Isto foi feito para verificar se o desequilíbrio da quantidade dos dados influía no desempenho da rede neural. Com isso, obtiveram-se os seguintes resultados:


- Acerto Médio: 58,48%
- Acerto Máximo: 64,54%
- Acerto Mínimo: 50,00%
- Desvio Padrão: 04,12%

O índice de acerto continuou não satisfatório, porém pôde-se constatar que havendo um equilíbrio maior nos dados, mais facilmente a rede consegue classificar os dados. Além disso, com os dados equilibrados, a maior parte dos erros de classificação ocorreu entre dados de ausência de falhas e falhas de baixa impedância.


Mesmo não tendo bons resultados de classificação nesse passo, este serviu para conferir se o erro de treinamento estava convergindo e para mostrar que os dados de curto circuito estavam sendo mapeados.



Nas Figuras 34 e 35 são mostrados, respectivamente, o erro de quantização para dados de treinamento em função do número de épocas, e um gráfico mostrando a grade bidimensional dos neurônios. Na Figura 35, a classe de motores sem falhas é representada por círculos, a classe de motores com falha de alta impedância é representada por um “asterisco” e a classe de motores com falha de baixa impedância é representada por triângulos.



**Figura 34 - Erro durante o treinamento 1 da rede neural. Fonte: Autor.**



**Figura 35 - Grade bidimensional 1 de neurônios. Fonte: Autor.**

A partir desta figura, pode-se concluir que, com esse treinamento, como os dados de motores com falhas de baixa impedância são bem menos similares aos outros tipos de dados, a maioria dos neurônios foi designado para representar esta classe.

Além disso, também é mostrado que os dados de motor em funcionamento normal e motor com falhas de alta impedância se encontram em regiões próximas na matriz de neurônios.

#### **4.3.2 Resultados do treinamento e teste 2 – Vizinhaça variável depois de determinadas iterações**

Em relação à classificação, neste passo, a rede neural obteve os seguintes resultados decorrentes de 10 treinamentos:

- Acerto Médio: 55,21%
- Acerto Máximo: 59,45%
- Acerto Mínimo: 50,00%
- Desvio Padrão: 02,97%

O acerto aumentou devido à nova maneira de treinar a rede. Este novo treinamento se resume a quatro fases:

Na primeira fase, os vetores de pesos dos neurônios vencedores e neurônios vizinhos são atualizados igualmente e estes são treinados desta forma por duas épocas. Além disso, a vizinhança espacial foi de 4 neurônios tanto horizontalmente como verticalmente (vizinhança retangular); ou seja, em uma única iteração, todos os neurônios podem ter seus valores atualizados de uma só vez. Este tipo de vizinhança foi representado na Figura 5.


Assim, como a vizinhança é grande em relação ao número de neurônios, nas duas primeiras épocas de treinamento os neurônios se concentraram sempre em um ponto próximo do “centro de massa” dos dados (local onde a maioria dos dados se concentra).

Na segunda fase, a vizinhança é reduzida para 3 neurônios e os neurônios vencedores e vizinhos continuam tendo seus pesos atualizados de forma igualitária. Esta fase se mantém por mais duas épocas.


Na terceira fase, a vizinhança é reduzida para 2 neurônios, os neurônios continuam sendo atualizados do mesmo modo da fase anterior, e esta fase também dura duas épocas.

Nesta última fase, a vizinhança passa a ser de 1 neurônio, porém a função de vizinhança utilizada nesta fase é a Equação 8. Esta fase dura as épocas restantes de treinamento.

A evolução destas fases durante o treinamento pode ser facilmente vista pela curva de erro representada na Figura 36.



**Figura 36 - Curva de erro durante o treinamento. Fonte: Autor.**



**Figura 37 - Matriz de Neurônios. Fonte: Autor.**

Já na Figura 37, pode-se ver a matriz de neurônios decorrente do teste deste passo.

Em comparação com o gráfico bidimensional de neurônios anterior (Figura 35), pode-se notar que mais neurônios foram designados tanto para a classe de motores sem falhas (representados por círculos), como para a classe com falhas de alta impedância. Também se pode notar que os neurônios designados para estas duas classes se encontram em regiões espacialmente próximas. Além disso, surgiu uma região onde houve dúvida em relação à classificação.

Como os resultados continuavam não satisfatórios, também tentou-se equilibrar os dados tanto no treinamento como no teste. Com isso obtiveram-se os seguintes resultados:

- Acerto Médio: 57,00%
- Acerto Máximo: 71,20%
- Acerto Mínimo: 47,00%
- Desvio Padrão: 05,17%

Conseguiu-se um acerto máximo maior que o passo anterior, porém o acerto médio foi 1% menor.

Como, mesmo com essa nova técnica de treinamento e com o equilíbrio dos dados o acerto continuou não satisfatório, decidiu-se modificar o teste.

#### **4.3.3 Resultados do treinamento e teste 3 – Teste modificado: classificação apenas entre motores com ou sem falhas**

Em relação à classificação, nesse passo, a rede neural obteve os seguintes resultados:

- Acerto Médio: 87,50%
- Acerto Máximo: 94,59%
- Acerto Mínimo: 83,00%
- Desvio Padrão: 03,06%


Esse acerto foi bem superior ao dos passos anteriores, comprovando que a maior parte dos erros se dava pela dificuldade desta rede na diferenciação entre falhas de curto-circuito de alta e baixa impedância.

Outro teste feito nesse passo foi calcular separadamente, após o treinamento, a porcentagem de acerto quando um dado de motor com falhas de curto-circuito é apresentado à rede, e a porcentagem de acerto quando um dado de motor ausente de falhas é apresentado à rede.

O acerto médio quando um dado com falhas é apresentado à rede foi de 94,50% e o acerto médio quando um dado ausente de falhas é apresentado a rede foi de 52,00%. Ou seja, os maiores erros ocorrem quando é mostrado um dado de motor sem falhas.

Isso se deve ao fato de que os mapas auto-organizáveis também fazem uma representação da quantidade de vetores de características de cada classe. Como 75% dos vetores de características apresentados a esta rede são dados de motores com falhas, os neurônios acabam classificando, após o treinamento, a maioria das próximas entradas como sinais de motores com falhas.

Um gráfico bidimensional, composto por duas características de todos os vetores do banco de dados utilizados e dos pesos dos neurônios (estes com linhas ligando os neurônios vizinhos), é mostrado na Figura 38. Nesta figura, os neurônios são representados por quadrados, e outros símbolos são os dados do banco de dados.



**Figura 38 – Distribuição dos neurônios nos dados. Fonte: Autor.**

#### **4.3.4 Resultados do treinamento e teste 4 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de alta impedância ou com ausência de falhas.**

Em relação à classificação, nesse passo, a rede neural obteve os seguintes resultados:

- Acerto Médio: 82,04%
- Acerto Máximo: 88,32%
- Acerto Mínimo: 79,76%
- Desvio Padrão: 02,72%


Nesse passo, o acerto médio foi de 82,02%. Houve uma pequena redução no acerto (comparado ao item anterior), isso ocorreu porque os dados de curto circuito de alta impedância são bastante similares aos dados de motor em funcionamento normal (Figura 33).

Através deste resultado, pode-se concluir que a rede neural proposta tem um alto índice de acerto para classificar o início da falha.

Como o processo de falha por curto-circuito inicia-se com alta impedância (NATARANJAN, 1989), e, se este for detectado prematuramente, a máquina pode ser reutilizada (THOMSON, 2001), este algoritmo se mostra robusto na solução do problema proposto.


A taxa média de acerto ao se mostrar dados de motor com falhas foi de 95%. Já a taxa média de acerto ao se mostrar motores sem falhas foi de 33%.

Na Figura 39 é mostrado o erro durante o treinamento da rede. Já na Figura 40 é mostrado um gráfico bidimensional da distribuição dos neurônios nos dados. Por fim, na Figura 41, é mostrada a grade de neurônios.




**Figura 39 - Erro durante treinamento 5. Fonte: Autor.**





**Figura 40 - Gráfico bidimensional após treinamento 5. Fonte: Autor.**



**Figura 41 - Grade de neurônios. Fonte: Autor.**

Na Figura 41, pode-se constatar que os neurônios que representam a classe de dados com falhas de alta impedância (círculos) ficaram agrupados em duas regiões divididas pelos neurônios representantes dos dados de motores sem falhas (pontos).

Também, neste passo, o conjunto de dados foi equilibrado para verificar se, nesta condição o acerto na classificação continuava o mesmo. Com isso, obtiveram-se os seguintes resultados:

- Acerto Médio: 78,17%
- Acerto Máximo: 82,53%
- Acerto Mínimo: 72,00%
- Desvio Padrão: 02,21%

O acerto médio foi um pouco reduzido, porém a classificação ficou mais equilibrada, visto que o desvio padrão diminuiu.

Em média, o acerto ao se apresentar um dado de motor com falhas de alta impedância e um dado de motor sem falhas é praticamente igual (50%).

#### **4.3.5 Resultados do treinamento e teste 5 – Conjunto de dados modificado: utilizando apenas dados de motores com falhas de baixa impedância ou com ausência de falhas.**

Em relação à classificação, nesse passo, a rede neural obteve os seguintes resultados:

- Acerto Médio: 81,23%
- Acerto Máximo: 86,27%
- Acerto Mínimo: 77,43%
- Desvio Padrão: 02,52%


A partir destes resultados, verificou-se que os acertos, em comparação com o passo 5, pouco se modificaram, ratificando que a maior dificuldade da rede estava realmente em diferenciar dados de curto-circuito de baixa impedância e dados de curto-circuito de alta impedância.

A taxa média de acerto ao se mostrar dados de motor com falhas foi de 92%. Já a taxa média de acerto ao se mostrar motores sem falhas foi de 37%.


Ao se comparar este resultado com o resultado anterior, pode-se concluir que é mais fácil para esta rede neural ter sucesso na classificação quando um dado de motor sem falhas é mostrado a ela.

Também, o acerto médio geral na classificação é um pouco menor que o do passo anterior. Isso se dá pelo fato de que, como mais neurônios são classificados como motor em funcionamento normal e existem mais dados de motores com falhas do que de motores com ausência dessas, o erro médio nesta classificação foi maior.


Na Figura 42 é mostrado o erro durante o treinamento da rede. Já na Figura 43 é mostrado um gráfico bidimensional da distribuição dos neurônios nos dados, Por fim, na Figura 44 é mostrada a grade de neurônios.



**Figura 42 - Erro durante o treinamento 6. Fonte: Autor.**



**Figura 43 – Gráfico bidimensional após treinamento 6. Fonte: Autor.**



**Figura 44 - Grade de neurônios. Fonte: Autor.**

Também neste passo, os dados foram equilibrados para comparar o resultado com estes mesmos dados estando desequilibrados. Com isso, obtiveram-se os seguintes resultados:


- Acerto Médio: 80,95%
- Acerto Máximo: 84,21%
- Acerto Mínimo: 77,38%
- Desvio Padrão: 02,38%

Assim como no passo anterior, o acerto médio diminuiu, porém a classificação ficou mais equilibrada, visto que os desvios padrões são menores.

#### **4.3.6 Resultados do Ajuste e Configuração final do algoritmo para detecção de falhas**

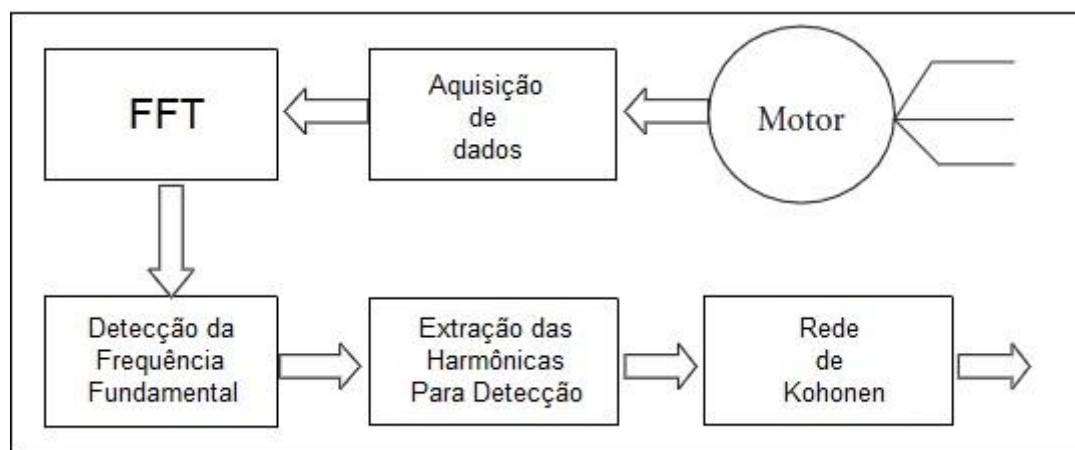
A partir da nova técnica de rotulação, as classes dos dados ficaram mais bem distribuídas na disposição da grade bidimensional de neurônios (fazendo com que as falhas fossem facilmente detectadas com análise visual da rede neural). Além disso, o acerto médio por parte desta rede neural continuou em níveis considerados satisfatórios (88,32%). Na Figura 45, é mostrada a disposição dos neurônios na grade bidimensional. Nela, os símbolos totalmente preenchidos são neurônios, e os símbolos restantes são os dados “trazidos” para o plano bidimensional. Os neurônios em forma de círculos são representantes dos dados de motores em condições normais de funcionamento, os em forma de triângulo são representantes dos dados de motores com falhas de curto-circuito de alta impedância, já os em forma de asterisco são representantes dos dados de motores com falhas de curto-circuito de baixa impedância.

A partir dos resultados de testes e treinamentos anteriores, definiu-se a configuração final do algoritmo. O diagrama de blocos lógicos é mostrado na Figura 46, e a lógica deste algoritmo, que pode ser subdividido em duas partes, é descrita a seguir.



**Figura 45 - Distribuição espacial dos neurônios. Fonte: Autor**

Fonte: Autor



**Figura 46 - Sequência lógica do algoritmo. Fonte: Autor**

Etapa de Aquisição e tratamento dos dados:

- Aquisição de todos os vetores de características (isto foi feito pois este programa funciona no modo *offline*).

- Aplicação da FFT em cada vetor de característica (no caso, em cada um dos 441 vetores)
- Para cada vetor, é feita uma varredura no seu espectro de frequências, de 5 Hz a 70 Hz para descobrir qual é a frequência fundamental de alimentação do motor. Isto é feito buscando o maior valor em módulo, da saída da função FFT.
- Descoberta a frequência fundamental, retiram-se as frequências harmônicas utilizadas para detecção de falhas. Para descobrir a 2ª harmônica, multiplicou-se a frequência fundamental por dois, e após isso se fez uma varredura do maior valor dentro de uma “janela” de 4 Hz. Por exemplo, se a frequência fundamental é 30 Hz, faz-se uma varredura entre 58 Hz e 62 Hz para procurar o maior valor. Isto foi feito para encontrar cada uma das harmônicas.

Etapa de treinamento, rotulação e teste:

- Cálculo da quantidade de vetores de características e da quantidade de atributos da matriz de características.
- Definição da quantidade de neurônios utilizados, da quantidade vetores utilizados para teste e para treinamento, do número de épocas e do passo de aprendizagem.
- Normalizações dos dados. Primeiramente, calcula-se a média e o desvio padrão para cada atributo de todos os vetores de características. Depois disso, utiliza-se a Equação 10. Por fim, as harmônicas de um dado vetor são divididas pela harmônica fundamental deste.
- Definição aleatória dos vetores de características utilizados no teste e no treinamento da rede neural
- Início do treinamento. Para cada época são feitos os seguintes passos: define-se a quantidade de vizinhos e a função de vizinhança (de acordo com o Subseção 4.3.2 deste trabalho), o passo de aprendizagem atual e o neurônio vencedor; atualizam-se os pesos do neurônio vencedor e de seus vizinhos; calcula-se o erro da época atual.
- Geração do gráfico de erro em função da época (para a verificação da convergência do erro).
- Geração dos gráficos bidimensionais (para a verificação da distribuição dos neurônios na massa de dados).

- Atribuição de rótulo a cada neurônio.
- Classificação dos dados de teste.
- Geração do gráfico 2D representando a malha de neurônios com sua vizinhança espacial.

Assim, pode-se constatar que este algoritmo se mostrou capaz de solucionar o problema proposto pelo trabalho, porém ainda não foi capaz de mostrar a evolução da porcentagem de curto-circuito.

Na tabela 9, são mostrados os resultados de cada etapa. Nas linhas onde há A sigla “Eq”, são mostrados os resultados de cada etapa quando os dados são “equilibrados”, ou seja, a porcentagem de dados para cada classe é igual.

ETAPA A3 - RESULTADOS				
	Acerto médio	Acerto máximo	Acerto mínimo	Desvio padrão
4.3.1	48,36%	55,40%	43,24%	3,32%
4.3.1 Eq	58,48%	68,00%	50,00%	4,12%
4.3.2	48,87%	55,00%	44,55%	2,97%
4.3.2 Eq	57,00%	71,20%	47,00%	5,17%
4.3.3	87,50%	94,59%	83,00%	3,06%
4.3.4	82,04%	88,32%	79,76%	2,72%
4.3.4 Eq	78,17%	82,53%	72,65%	2,21%
4.3.5	82,04%	88,32%	79,76%	2,52%
4.3.5 Eq	80,95%	84,21%	77,38%	2,38%
4.3.6	88,32%	90,62%	82,53%	2,41%

**Tabela 9 – Resultados da etapa 4.3**



## **5 CAPÍTULO 5 – CONCLUSÃO**

### **5.1 Quanto ao tema**

O tema estudado (detecção de falhas por curto-circuito em motores) reuniu várias disciplinas estudadas durante todo o curso de Engenharia Mecatrônica, tais como acionamento de máquinas elétricas, instrumentação, programação, sistemas lineares e redes neurais.

Assim, devido à multidisciplinaridade do tema, este é de grande importância para a fixação e aprofundamento de alguns conceitos, e para que se aplique, na prática, os conceitos aprendidos em sala de aula, durante o curso.

### **5.2 Quanto ao problema**

O problema proposto é bastante desafiador, visto que, como os dados de motores com falhas incipientes por curto-circuito entre espiras do estator são bastante parecidos com os dados de motores com ausência de falhas, inúmeras adaptações no algoritmo (tanto no modo de tratar os dados como no treinamento e teste da rede neural) tiveram que ser feitas para que os resultados melhorassem.

### **5.3 Quanto aos objetivos**

#### **5.3.1 Específicos**

Em relação aos objetivos específicos, todos foram concretizados, visto que o estudo das possibilidades de detecção de falhas em motores de indução, a montagem da bancada de testes, os ensaios representativos de operação do motor, a descrição das características, especificações e requisitos para o desenvolvimento do algoritmo neural, o projeto da rede SOM Matricial, e a avaliação do desempenho deste detector foram realizados.

### **5.3.2 Geral**

O objetivo geral foi parcialmente conseguido, visto que o algoritmo neural aplicado classificou bem os dados entre motores de indução com ou sem falha, porém, na evolução da falha, a classificação apresentou baixo índice de acerto.

### **5.4 Quanto à metodologia e procedimentos adotados**

No que diz respeito aos procedimentos adotados, as etapas que mais demandaram tempo foram as etapas preliminares, visto que vários ajustes tiveram que ser feitos na estrutura mecânica devido ao não funcionamento da célula de carga, uma nova placa de circuito impresso do amplificador e filtro para o sensor hall teve que ser montada, e o acoplamento do motor e o eixo de aço teve que ser feito com muito cuidado para que houvesse o mínimo possível de vibrações por parte deste acoplamento.

### **5.5 Quanto aos resultados obtidos**

Obteve-se uma alta taxa média de acerto (88,32%) na detecção de falhas por curto circuito, porém houve dificuldade na detecção da evolução deste tipo de falha, visto que a detecção entre falhas de baixa impedância, falhas de alta impedância e motores sem falhas obteve uma taxa média de acerto de apenas 48,87%.

### **5.6 Limitações**

Mesmo com bons resultados, este trabalho teve algumas limitações.

Primeiramente, por ter sido feito dentro de um laboratório de pesquisa no qual a estrutura foi melhorando no decorrer do trabalho, algumas etapas foram mais demoradas, visto que a confecção das placas de circuito impresso foi feita de modo artesanal (com percloroeto de ferro e prensa), e a estrutura mecânica teve que ser movida do laboratório LPE para o laboratório LME (pois somente neste havia um conversor de frequência capaz de fornecer a corrente elétrica necessária para alimentar o motor).

Também, a falta de recursos não permitiu que aquisição de dados fosse feita em mais de um modelo de motor de indução.

Além disso, a estrutura mecânica montada não permitiu uma medição indireta do conjugado por meio de uma célula de carga. Não foi construída uma nova estrutura pela falta de tempo.

### **5.7 Considerações gerais**

No geral, este trabalho é importante por mostrar alguns conceitos de redes neurais não supervisionadas e se mostra promissor para que um futuro sistema supervisorio de falhas por curto-circuito entre espiras do estator de um motor de indução trifásico seja desenvolvido.

### **5.8 Sugestões para trabalhos futuros**

Por fim, algumas sugestões para trabalhos futuros:

- Utilizar outras redes neurais, tais como RBF e MLP (pois estas fazem um mapeamento não linear dos dados) para comparar o resultado destas com os resultados obtidos neste trabalho.
- Incrementar o banco de dados aqui gerado com dados de motores com outros tipos de falhas e com dados simulados.
- Adaptar o algoritmo baseado na Rede SOM 2-D, para a detecção online de falhas no motor de indução trifásico gaiola de esquilo.
- Implementação de um dispositivo eletrônico que, através da leitura da corrente de umas das fases de um conversor de frequências, detecte falhas incipientes de curto-circuito em motores de indução trifásicos.

## REFERÊNCIAS

AGILENT TECHNOLOGIES. **Agilent 2300A Series USB Modular Multifunction Data Acquisition Device – Data Sheet**, 2012. Disponível em: <http://cp.literature.agilent.com/litweb/pdf/5991-0566EN.pdf> acessado às 18hrs do dia 18/11/2012.

BARBOUR, A.; THOMSON, W. T. **Finite element study of rotor slot designs with respect to current monitoring for detecting static airgap eccentricity in squirrel-cage induction motors**. IEEE Industry Application, p. 112-119, 1997.

BELLINI et al. **Closed loop control impact on the diagnosis of induction motors faults**. Industry Applications Conference, 1999.

BENBOUZID, M. E. H. **Bibliography on Induction Motor Faults Detection and Diagnosis**. IEEE Transactions on Energy Conversion .Vol. 14, No 4. 1999.

BONNET, A. H. **Root Cause Failure Analysis for AC Induction Motors in the Petroleum and Chemical Industry**. Petroleum and Chemical Industry Conference (PCIC), 2010.

BRAGA, A. et al. **Redes Neurais Artificiais: Teoria e Aplicações**. Rio de Janeiro. Ed. LivrosTécnicos e Científicos. 2000.

BRICKLEY, C. H. **Reducing motor costs through chemistry**. Electrical Electronics Insulation Conference and Electrical Manufacturing & Coil Winding Conference, 1993, Chicago.

CAMPOS, M. M.; CARPENTER, G. A. WSOM: **Building adaptive wavelets with self-organizing maps**. Neural Networks Proceedings, 1998.

CARDOSO, A. J.; SARAIVA, E. S. **Computer-Aided Detection of Airgap Eccentricity in Three-phase induction motors by park's vector approach.** IEEE Transactions on Industry Applications, Vol. 29, n. 5, 1993.

DORRELL, D. G. et al. **Combined Effects of Static and Dynamic Eccentricity on air gap flux waves and the application of current monitoring to detect dynamic eccentricity in 3-phase induction motors.** Electrical and Machine Drives, 1995. Conference publication n. 412 IEEE.

FABBRO, P. A. **Projeto de um amplificador de instrumentação CMOS integrado.** Dissertação (Mestrado em Engenharia Elétrica) – Engenharia Elétrica, Universidade Estadual de Campinas. 2002.

FITZGERALD A. E.; Kingsley, C; Umans, S. D. **Máquinas Elétricas com Introdução à eletrônica de potência**, 6ª Ed. 2008.

FRANCHI, C. **Acionamentos Elétricos.** São Paulo: Ed. Érica, 2008.

FRANCISCO, A. M. S. **Motores de Indução trifásicos**, 2006. Disponível em: [http://www.estv.ipv.pt/PaginasPessoais/lpestanda/maquinas%20el%C3%A9ctricas%202/aulas%20te%C3%B3ricas/Motores\\_inducao\\_tri.pdf](http://www.estv.ipv.pt/PaginasPessoais/lpestanda/maquinas%20el%C3%A9ctricas%202/aulas%20te%C3%B3ricas/Motores_inducao_tri.pdf) Acessado às 23hrs do dia 15/03/2012.

FRANK, A. & ASUNCION, A. (2010). **UCI Machine Learning Repository** [<http://archive.ics.uci.edu/ml>]. Irvine, CA: University of California, School of Information and Computer Science.

GHATE, V. N. ; DUDUL, S. V. **Optimal MLP neural network classifier for fault detection of three phase induction motor.** Expert Systems with Applications 37. 2010.

HAN, T. et al. **Fault Diagnosis System of Induction Motors Based on Neural Network and Genetic Algorithm Using Stator Current Signals.** International Journal of Rotating Machinery.2006. 13 pgs.

HAYKIN, S. **Redes Neurais: Princípios e Práticas**. Porto Alegre: Ed. Bookman, 2001.

HUSH, D. R. et al. **Neural Networks in fault detection: A case study**. American Control Conference. 1997.

INDIRA, S.U.; RAMESH, A.C. **Image Segmentation Using Artificial Neural Network and Genetic Algorithm: A Comparative Analysis**. Process Automation, Control and Computing (PACC), International Conference, p. 1\_6 2011.

JOKSIMOVIC, G. M.; PENMAN, J. **The detection of inter-turn short circuits in the stator windings of operating motors**. IEEE Transactions on Industrial Electronics, v. 47, n. 5, p. 1078\_1084, 2000.

JI-HONG, R. ; JIANG-CHENG, C. ; NAN, W. **Visual Analysis of SOM Network in Fault Diagnosis**. International Conference on Physics Science and Technology, p. 333\_338 2011.

KLIMAN, G. B. et al. **Stator Current Harmonics and Their Casual Vibrations: A Preliminary Investigation of Sensorless Vibration Monitoring Applications**. IEEE TRANSACTIONS ON INDUSTRY APPLICATIONS, VOL. 35, NO. 1. 1999.

KOHONEN, T. **The Self-Organizing Map**. Proceedings of the IEEE, vol. 78, No. 9, 1990.

MALIJKOVIC, Z.; CETTOLO, M.; PAVLICA, M. "The Impact of the Induction Motor on Short-Circuit Current", IEEE Ind. Application Magazine, Vol. 7, No. 4, 2001, pp.11-17.

MEDEIROS, C. M. S. **Uma contribuição ao problema de seleção de modelos neurais usando o princípio da máxima correlação de erros**. 2008. 144 f. Tese (Doutorado em Engenharia de Teleinformática) – Engenharia de Teleinformática, Universidade Federal do Ceará.

MONTEIRO, I. Q. **Métodos de aprendizado de máquina para reconhecimento de faces: uma comparação de desempenho**. 2009. 130 f. Dissertação (Mestrado em engenharia de teleinformática) – Engenharia de Teleinformática, Universidade Federal do Ceará.

MELLO JUNIOR, A. G.; FAGÁ, M. T. W. **Substituição de motores elétricos por motores de combustão interna de ciclo Otto a gás natural em instalações de bombeamento de petróleo e seus derivados**. In: CONGRESSO BRASILEIRO DE P&D EM PETRÓLEO E GÁS, 3, 2005, Salvador. Anais do 3o Congresso Brasileiro de P&D em Petróleo e Gás.

NATARANJAN, R. **Failure identification of induction motors by sensing unbalanced stator currents**. IEEE Transactions on Energy Conversion, v. 4, n. 4, p. 585\_590, 1989.

NANDI, S.; BHARADWAJ, R. M.; TOLIYAT, H. A. **Performance analysis of a three-phase induction motor under mixed eccentricity condition**. IEEE Transactions on Energy Conversion, v. 17, n. 3, p. 392\_399, 2002.

NANDI, S.; TOLIYAT, H. A.; LI, X. **Condition monitoring and fault diagnosis of electrical machines - a review**. IEEE Transactions on Energy Conversion, v. 20, n. 4, p. 719\_729, 2005.

NIRALI, R.; SHAH, S. K. **Fuzzy Decision Based Soft Multi Agent Controller for Speed Control of Three Phase Induction Motor**. In: International Journal on Soft Computing ( IJSC ), Vol.2, No.3, 2011.

PENMAN, J.; SEDDING, H. G.; FINK, W. T. **Detection and location of interturn short circuits in the stator windings of operating motors.** IEEE Transactions on Energy Conversion, v. 9, n. 4, p. 652\_658, 1994.

PERTENCE, A. J. **Amplificadores Operacionais e Filtros Ativos: teoria, projetos, aplicações e laboratório.** 4ª Edição, São Paulo: McGraw-Hill, 1988.

REIS, T. A. **Implementação de uma FFT para computação reconfigurável de alto desempenho.** 2008. Trabalho de Graduação – Curso de Ciência da Computação. Universidade Federal de Santa Maria, Santa Maria.

RONGFENG, Y. et al. **The self-organizing map and fuzzy control for sensorless induction motor speed control.** Sixth International Conference on Natural Computation, p. 1406-1409. 2010.

SANTOS, A. H. M. et al. **Conservação de Energia: Eficiência Energética de Instalações e Equipamentos.** 2.ed. [S.l.]: Eletrobrás/PROCEL - Escola Federal de Engenharia de Itajubá-MG, 2001. ISBN 85-902115-1-7.

SAWA, T.; KUME, T. **Motor Drive Technology – History and Visions for the Future.** In: ANNUAL IEEE POWER ELECTRONICS SPECIALISTS CONFERENCE, 35, 2004, Aachen, Alemanha.

SINGH, G. K. ; KAZAZ, S. A. S. **Induction Machine Drive Condition Monitoring and Diagnostic Research – A Survey.** Electric Power Systems Research, vol. 64, no. 2, pp. 145-158, 2003.

SHAH, J. Z.; SALIM, N. B.A **Fuzzy Kohonen SOM Implementation and Clustering of Bio-active Compound Structures for Drug Discovery.** Computational Intelligence and Bioinformatics and Biology, 2006.



TALLAM, R. M. et al. **A survey of methods for detection of stator related faults in induction machines**. In: Proceedings of the IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives (SDEMPED'03). [S.l.: s.n.], 2003.p. 35\_46.

TEKTRONIX. **TDS 210 & TDS 220 Digital Real-time Oscilloscopes**. In: <http://www.tequipment.net/TektronixTDS210.html>.

THANGARAJ, R. et al. **Optimal Design of Induction Motor for a Spinning Machine Using Population Based Metaheuristics**, 2010. In: COMPUTER INFORMATION SYSTEMS AND INDUSTRIAL MANAGEMENT APPLICATIONS (CISIM), Luxembourg, France.

THOMSON, W. T. **On-line mcsa to diagnose shorted turns in low voltage stator windings of 3-phase induction motors prior to failure**. In: Proceedings of the IEEE International Conference on Electric Machines and Drives (IEMDC'01). [S.l.: s.n.], 2001. p. 891\_898.

TZAFESTAS, S. G. **Fault Diagnosis Via Local Neural Networks**. Mathematics and Computer in Simulation, 60. Ed. Elsevier, 2002.

VICO, J.; HUNT, R. **Projection Principle for Electrical Motors in the Cement Industry**. Cement Industry Technical Conference, p. 1-13. 2010 IEEE-IAS/PCA 52nd.

WEG. **Motores de Indução Alimentados por Inversores de Frequência PWM**, 2009. Disponível em: <http://catalogo.weg.com.br/files/wegnet/WEG-motores-de-inducao-alimentados-por-inversores-de-frequencia-pwm-027-artigo-tecnico-portugues-br.pdf>.

WEG. **Manual do Inversor de Frequência, série: CFW-09**, 2011. Disponível em: <http://ecatalog.weg.net/files/wegnet/WEG-cfw-09-manual-do-usuario-0899.5298-4.4x-manual-portugues-br.pdf>.

WEIDONG, J. et al. **A Novel Compound Neural Network for Fault Diagnosis.** Mechatronic and Embedded Systems and Applications, Proceedings of the 2nd IEEE/ASME International, p. 1\_4. 2006.

XU, Y. et al. **Digital Modulation Recognition Method Based on Self-Organizing Map Neural Networks.** Wireless Communications, Network and Mobile Computing, p. 1\_4. 2008.

YADAV, M.; WADHWANI, S. **Automatic Fault Classification of Rolling Element Bearing using Wavelet Packet Decomposition and Artificial Neural Network.** International Journal of Engineering and Technology Vol.3 (4), 2011, 270-276.

YOU, X. e ZHANG, W. **Fault Diagnosis of Frequency Converter in Wind Power System Based on SOM Neural Network.** International Workshop on Information and Electronics Engineering. p. 3132–3136. 2012.

ZANG, G. P. **Neural Network for Classification: A Survey.** IEEE Transactions on Systems, Man and Cybernetics, Part C (Applications and Reviews).Vol. 30, No. 4. (Nov 2000), pp. 451-462.

ZAHNG, L.; KONG, J.; ZENG, X.; REN, J. et al. **Plant Species Identification Based on Neural Network.** International Conference on Natural Computation. 4. p. 90-94. 2008.

## APÊNDICES

### APÊNDICE A – Descrição dos bancos de dados utilizados para testes

O Banco de dados Íris é provavelmente o mais conhecido na literatura de reconhecimento de padrões. Este possui três classes, cada uma representando um tipo de planta Iris (*Setosa*, *Versicolour* e *Virginica*). Neste banco de dados, cada classe possui cinquenta vetores de características. Cada vetor de características possui quatro características numéricas (representando, respectivamente, o comprimento da sépala, a largura da sépala, o comprimento da pétala e a largura da pétala) e o nome da classe a qual o vetor pertence.

O Banco de dados Dermatologia foi formado pela dificuldade apresentada no diagnóstico diferencial das doenças *erythmato-squamous* (eritêmato-escamosas). Este banco possui seis classes, cada um representando um tipo de doença (“psoriasis” com 116 vetores, “seboeic dermatitis” com 61 vetores, “lichen planus” com 72 vetores, “pityriasis rosea” com 49 vetores, “cronic dermatitis” com 52 vetores e “pityriasis rubra pilaris” com 20 vetores). Os vetores de características possuem: um atributo referente a idade de cada paciente, um atributo referente a classe a qual o vetor de características pertence e trinta e três atributos lineares com valores “0”, “1”, “2” ou “3” (0 indica que determinada característica não estava presente, 3 indica a máxima quantidade possível de alguma característica, e 1, 2 indicam valores intermediários).

O Banco de dados Vinho é resultado de uma análise química de vinhos vindos da mesma região da Itália, mas derivados de três cultivares diferentes. Os vetores de características são constituídos de treze atributos referentes a treze constituintes achados em cada tipo de vinho (*Alcohol*, *Malicacid*, *Ash*, *Alcalinityofash*, *Magnesium*, *Total phenols*, *Flavanoids*, *Nonflavanoidphenols*, *Proanthocyanins*, *Color intensity*, *Hue*, *OD280/OD315 of diluted wine sand Proline*). Número de vetores de características por cada classe: 59 para a classe 1, 71 para a classe 2 e 48 para a classe 3.

# APENDICE B – Placas de circuito impresso utilizadas pelo autor




Figura 47 - PCB do Circuito Amplificador. Fonte: Autor.

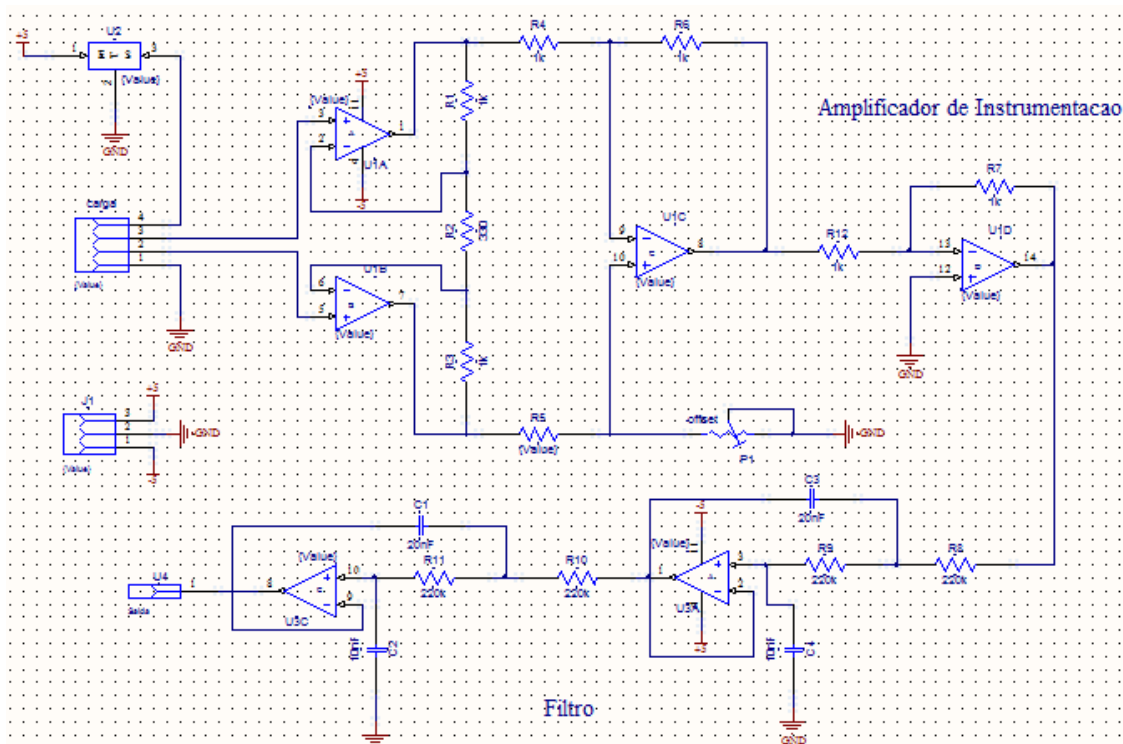



Figura 48 - Esquemático do Amplificador e Filtro para Célula de Carga. Fonte: Autor.



**Figura 49 - PCB do circuito amplificador e filtro para o sensor hall. Fonte: Autor.**

## APENDICE C – Equipamentos Utilizados pelo autor




Figura 50 - Osciloscópio Tektronix TDS 210. Fonte: Autor.



Figura 51 - Célula de carga da marca Aeph. Fonte: Datasheet. do Fabricante



Figura 52 - Fonte Chaveada de Tensão Contínua Minipa MPL-3305. Fonte: <http://www.socintec.com.br/MaisProduto.asp?Produto=455> (acessado no dia 16/02/2012).



Figura 53 - Conversor de Frequência CFW-09. Fonte: Datasheet.do Fabricante